

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Направление подготовки
"01.03.02. Прикладная математика и информатика"

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №1
"Гистограммы и плотности распределений"

Работу
выполнил:
Житков Н. С.
Группа:
5030102/30201

Санкт-Петербург
2026

Содержание

1	Постановка задачи	3
2	Теоретическая часть	3
3	Реализация	4
4	Результаты	5
5	Обсуждение	7
6	Выводы	7
7	Список литературы	8
8	Приложение	8

1 Постановка задачи

Цель работы: изучить влияние объёма выборки на определение характера распределения величины с помощью гистограммы.

Задачи:

- Сгенерировать выборки объёмами $n = 10, 100, 1000$ для пяти распределений:
 1. Нормальное $N(x; 0, 1)$;
 2. Коши $C(x; 0, 1)$;
 3. Лапласа $L(x; 0, \frac{1}{\sqrt{2}})$;
 4. Пуассона $P(k; 10)$;
 5. Равномерное $U(x; -\sqrt{3}, \sqrt{3})$.
- Для каждой выборки построить гистограмму и теоретическую кривую плотности распределения.
- Сравнить гистограммы при разных n .
- Сделать выводы о скорости сходимости эмпирического распределения к теоретическому и о том, как влияет размер выборки на определение характера распределения величины с помощью гистограммы.

2 Теоретическая часть

Гистограмма. Гистограмма — это статистический метод оценки плотности распределения. Выборка разбивается на интервалы (бины), подсчитывается количество попавших в каждый интервал наблюдений, затем строится столбчатая диаграмма. При нормировке на общую площадь (плотность) высота столбцов приближает теоретическую плотность.

Выбор числа интервалов. Слишком малое число бинов сглаживает детали, слишком большое — создаёт шум. В работе для непрерывных распределений используется автоматический метод 'auto' библиотеки `matplotlib`, который реализует правило Фридмана–Дьякониса:

$$h = 2 \cdot \frac{\text{IQR}}{n^{1/3}},$$

где IQR — межквартильный размах, а h — это ширина одного интервала (бина). Для распределения Пуассона бины выбраны шириной 1 и центрированы по целым значениям. Теоретические кривые строятся по точкам, вычисленным непосредственно прямой подстановкой в функции плотностей распределений.

IQR вычисляется по выборке:

1. Упорядочиваем данные по возрастанию.;
2. Находим Q_1 — значение, ниже которого лежит 25% данных;
3. Находим Q_3 — значение, ниже которого лежит 75% данных;
4. $\text{IQR} = Q_3 - Q_1$.

Исследуемые распределения.

1. Нормальное распределение $N(x; 0, 1)$:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad x \in R.$$

$$Mx = 0, Dx = 1$$

2. Распределение Коши $C(x; 0, 1)$:

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad x \in R.$$

$$Mx = 0$$

3. Распределение Лапласа $L(x; 0, 1/\sqrt{2})$:

$$f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}, \quad x \in R.$$

$$Mx = 0, Dx = 1$$

4. Распределение Пуассона $P(k; 10)$:

$$P(k) = \frac{10^k e^{-10}}{k!}, \quad k = 0, 1, 2, \dots$$

$$Mx = 10, Dx = 10$$

5. Равномерное распределение $U(x; -\sqrt{3}, \sqrt{3})$:

$$f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, & |x| \leq \sqrt{3}, \\ 0, & |x| > \sqrt{3}. \end{cases}$$

$$Mx = 0, Dx = 1$$

3 Реализация

Язык программирования: Python 3.13

Среда разработки: VS Code

Библиотеки:

- `numpy` — генерация выборок;
- `scipy.stats` — вычисление теоретических плотностей и вероятностей;
- `matplotlib.pyplot` — построение графиков.

Алгоритм работы программы:

1. Для каждого распределения и каждого объёма выборки n генерируется массив случайных чисел.
2. Для непрерывных распределений гистограмма строится с параметром `density=True` (нормировка) и автоматическим выбором числа бинов (`bins='auto'`).

3. Для распределения Пуассона задаются бины от -0.5 до 20.5 с шагом 1 , что гарантирует попадание каждого целого значения в свой интервал; гистограмма также нормируется на единицу.
4. Теоретическая кривая плотности вычисляется по формулам из теоретической части и накладывается на гистограмму.
5. Для каждого распределения создаётся рисунок с тремя подграфиками (для $n = 10, 100, 1000$) и сохраняется в PNG-файл.

4 Результаты

На рисунках 1–5 представлены гистограммы выборок разного объёма совместно с теоретическими кривыми.



Рис. 1: Нормальное распределение $N(0,1)$. При увеличении n гистограмма становится более похожей на плотность распределения.




Рис. 2: Распределение Коши $C(0,1)$. Из-за тяжёлых хвостов даже при $n = 1000$ могут появляться выбросы, искажающие гистограмму. Сходимость медленная..




Рис. 3: Распределение Лапласа $L(0, 1/\sqrt{2})$. При увеличении n гистограмма становится более похожей на плотность распределения.




Рис. 4: Распределение Пуассона $P(10)$. При малых n ($n = 10$) ступеньки сильно отличаются от теоретических вероятностей; при $n = 100$ соответствие улучшается; при $n = 1000$ гистограмма намного лучше повторяет теоретические значения.




Рис. 5: Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$. Уже при $n = 100$ гистограмма близка к прямоугольной форме; при $n = 1000$ границы определяются достаточно чётко.

5 Обсуждение

В ходе выполнения лабораторной работы были сгенерированы выборки объёмом $n = 10, 100, 1000$ для пяти распределений: нормального, Коши, Лапласа, Пуассона и равномерного. Для каждой выборки построены гистограммы, совмещённые с теоретическими кривыми плотности. Анализ полученных графиков (рис. 1–5) позволяет сделать следующие наблюдения.

Влияние объёма выборки. Для всех распределений с увеличением n гистограмма становится более гладкой и приближается к теоретической кривой. При $n = 10$ форма гистограммы сильно зависит от случайности и может существенно отличаться от ожидаемой. При $n = 100$ уже проявляются характерные черты распределения, а при $n = 1000$ гистограмма практически совпадает с теоретической кривой (за исключением особенностей, связанных с выбросами для распределения Коши). Это демонстрирует состоятельность гистограммы как оценки плотности распределения.

Особенности различных распределений.

- **Нормальное распределение** $N(0, 1)$: быстро сходится, уже при $n = 100$ форма близка к колоколообразной, при $n = 1000$ отличия минимальны.
- **Распределение Лапласа** $L(0, 1/\sqrt{2})$: также хорошо аппроксимируется, острый пик в нуле становится заметен при $n \geq 100$.
- **Равномерное распределение** $U(-\sqrt{3}, \sqrt{3})$: при $n = 100$ границы интервала определяются достаточно чётко, при $n = 1000$ прямоугольная форма почти совпадает с теорией.
- **Распределение Пуассона** $P(10)$: дискретность сохраняется при любом n , но относительные частоты при $n = 1000$ очень близки к теоретическим вероятностям; при $n = 10$ возможны значительные отклонения из-за малого числа наблюдений.
- **Распределение Коши** $C(0, 1)$: из-за тяжёлых хвостов в выборках появляются экстремальные значения, которые влияют на нормировку гистограммы, занижая высоту столбцов в центральной области. Тем не менее, с ростом n форма пика в окрестности нуля становится более отчётливой, хотя сходимость медленнее, чем у распределений с экспоненциально убывающими хвостами.

Выбор числа интервалов гистограммы. Использование автоматического метода `bins='auto'` в библиотеке `matplotlib`, реализующего правило Фридмана–Дьякониса, позволило получить адекватное количество интервалов для каждого набора данных. Это правило учитывает межквартильный размах и объём выборки, что даёт хороший баланс между сглаживанием и детализацией. Для дискретного распределения Пуассона бины были заданы вручную (с шириной 1), чтобы корректно отобразить вероятности целых значений.

Таким образом, полученные результаты полностью соответствуют теоретическим представлениям математической статистики о поведении эмпирических оценок плотности.

6 Выводы

В ходе лабораторной работы были выполнены все поставленные задачи:

1. Сгенерированы выборки объёмом $n = 10, 100, 1000$ для пяти заданных распределений.

2. Построены гистограммы с наложенными теоретическими кривыми плотности, что позволило визуально оценить степень соответствия.
3. Проведён анализ влияния размера выборки на вид гистограммы:
 - При малых n гистограмма может не отражать истинную форму распределения.
 - С увеличением n гистограмма стабилизируется и приближается к теоретической кривой, что подтверждает состоятельность гистограммы как оценки плотности.
 - Скорость сходимости зависит от типа распределения: для распределений с лёгкими хвостами (нормальное, Лапласа, равномерное) она выше, для распределения Коши — ниже из-за влияния редких, но больших выбросов.
 - Для дискретного распределения Пуассона гистограмма при $n = 1000$ практически совпадает с теоретическими вероятностями, демонстрируя закон больших чисел.

Итоговый вывод. Размер выборки критически важен для определения характера распределения с помощью гистограммы. При недостаточном объёме данных можно сделать ошибочные выводы о форме распределения, тогда как при достаточно большом n гистограмма даёт надёжное представление о законе распределения случайной величины.

7 Список литературы

1. Кобзарь А.И. Прикладная математическая статистика. — М.: Физматлит, 2006.
2. Боровков А.А. Математическая статистика. — М.: Наука, 1984.
3. Документация библиотек Numpy и SciPy — <https://docs.scipy.org/doc/>
4. Документация Matplotlib — <https://matplotlib.org/stable/contents.html>

8 Приложение

Ссылка на репозиторий с исходным кодом: <https://github.com/zhitkovns/matstat>