

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Направление подготовки
"01.03.02. Прикладная математика и информатика"

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №1
"Гистограммы и плотности распределений"

Работу
выполнил:
Житков Н. С.
Группа:
5030102/30201

Санкт-Петербург
2026

Содержание

1	Постановка задачи	3
2	Теоретическая часть	3
3	Реализация	5
4	Результаты	5
5	Обсуждение	8
6	Выводы	8
7	Список литературы	9
8	Приложение	9

1 Постановка задачи

Цель работы: изучить влияние объёма выборки на определение характера распределения величины с помощью гистограммы.

Задачи:

- Сгенерировать выборки объёмами $n = 10, 100, 1000$ для пяти распределений:
 1. Нормальное $N(x; 0, 1)$;
 2. Коши $C(x; 0, 1)$;
 3. Лапласа $L(x; 0, \frac{1}{\sqrt{2}})$;
 4. Пуассона $P(k; 10)$;
 5. Равномерное $U(x; -\sqrt{3}, \sqrt{3})$.
- Для каждой выборки построить гистограмму и теоретическую кривую плотности распределения.
- Сравнить гистограммы при разных n .
- Сделать выводы о скорости сходимости эмпирического распределения к теоретическому и о том, как влияет размер выборки на определение характера распределения величины с помощью гистограммы.

2 Теоретическая часть

Гистограмма. Гистограмма — это статистический метод оценки плотности распределения. Выборка разбивается на интервалы (бины), подсчитывается количество наблюдений, попавших в каждый интервал, затем строится столбчатая диаграмма. При нормировке на единичную площадь (параметр `density=True`) высота столбцов приближает теоретическую плотность вероятности.

Выбор числа интервалов. Качество гистограммы существенно зависит от количества интервалов. Слишком малое число бинов приводит к чрезмерному сглаживанию и потере деталей, слишком большое — к появлению ложных пиков и шума. В работе используются несколько правил для определения оптимального числа интервалов в зависимости от объёма выборки и типа распределения.

- **Правило Фридмана–Дьякониса** реализовано в методе `'auto'` библиотеки `matplotlib`. Оно определяет ширину интервала h как

$$h = 2 \cdot \frac{\text{IQR}}{n^{1/3}},$$

где IQR — межквартильный размах выборки. Это правило минимизирует среднеквадратичную ошибку оценки плотности и хорошо работает для больших выборок.

- **Правило $\sqrt{n}$** (квадратного корня) задаёт число интервалов как округлённое значение квадратного корня из объёма выборки:

$$k = \lceil \sqrt{n} \rceil.$$

Оно часто применяется при малых объёмах данных ($n \leq 100$), так как даёт умеренное количество бинов и уменьшает «дырявость» гистограммы. В `matplotlib` это правило доступно через значение `'sqrt'`.

Для дискретного распределения Пуассона бины выбраны шириной 1 и центрированы по целым значениям, что соответствует его природе. При малых n (10, 100) для Пуассона также использовалось правило $\sqrt{n}$ для группировки данных, чтобы избежать пустых интервалов; при $n = 1000$ бины оставлены точными (ширина 1), чтобы продемонстрировать сходимость относительных частот к теоретическим вероятностям.

Межквартильный размах (IQR). IQR вычисляется по выборке следующим образом:

1. Упорядочить данные по возрастанию.
2. Найти первый квартиль Q_1 — значение, ниже которого лежат 25% данных.
3. Найти третий квартиль Q_3 — значение, ниже которого лежат 75% данных.
4. Вычислить $IQR = Q_3 - Q_1$.

IQR является устойчивой мерой разброса и используется в правиле Фридмана–Дьякониса.

Исследуемые распределения.

1. **Нормальное распределение** $N(x; 0, 1)$:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad x \in R.$$

$$Mx = 0, Dx = 1$$

2. **Распределение Коши** $C(x; 0, 1)$:

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad x \in R.$$

$$Mx = 0$$

3. **Распределение Лапласа** $L(x; 0, 1/\sqrt{2})$:

$$f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}, \quad x \in R.$$

$$Mx = 0, Dx = 1$$

4. **Распределение Пуассона** $P(k; 10)$:

$$P(k) = \frac{10^k e^{-10}}{k!}, \quad k = 0, 1, 2, \dots$$

$$Mx = 10, Dx = 10$$

5. **Равномерное распределение** $U(x; -\sqrt{3}, \sqrt{3})$:

$$f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, & |x| \leq \sqrt{3}, \\ 0, & |x| > \sqrt{3}. \end{cases}$$

$$Mx = 0, Dx = 1$$

3 Реализация

Язык программирования: Python 3.13

Среда разработки: VS Code

Библиотеки:

- `numpy` — генерация выборок;
- `scipy.stats` — вычисление теоретических плотностей и вероятностей;
- `matplotlib.pyplot` — построение графиков.

Алгоритм работы программы:

1. Для каждого распределения и каждого объёма выборки $n = 10, 100, 1000$ генерируется массив случайных чисел с использованием соответствующего генератора из `numpy.random`.
2. Для каждого набора данных строится гистограмма с параметром `density=True` (нормировка на единичную площадь). Выбор числа интервалов (бинов) адаптируется под тип распределения и объём выборки:
 - Для непрерывных распределений (кроме Коши) при $n \leq 100$ используется правило $\sqrt{n}$ (`bins='sqrt'`), что даёт более гладкие гистограммы на малых данных; при $n = 1000$ применяется автоматическое правило Фридмана–Дьякониса (`bins='auto'`).
 - Для распределения Коши, характеризующегося тяжёлыми хвостами, гистограмма строится только в центральной области, чтобы избежать искажения масштаба выбросами. Для этого используется параметр `range`, ограничивающий интервал построения:
 - при $n = 10$: интервал $[-10, 10]$, число бинов = 20;
 - при $n = 100$: интервал $[-15, 15]$, число бинов = 30;
 - при $n = 1000$: интервал $[-20, 20]$, число бинов = 100.
 - Для распределения Пуассона при $n \leq 100$ используется автоматический подбор бинов (`bins='auto'`) для группировки данных и устранения пустых промежутков. При $n = 1000$ применяются фиксированные бины шириной 1 (от -0.5 до 20.5), чтобы точно отобразить дискретную структуру.
3. Теоретическая кривая плотности вычисляется по аналитическим формулам и накладывается на гистограмму. Для непрерывных распределений кривая строится по 200 точкам, равномерно распределённым в отображаемом интервале.
4. Для каждого распределения создаётся рисунок с тремя подграфиками (для $n = 10, 100, 1000$) и сохраняется в PNG-файл.

4 Результаты

На рисунках 1–5 представлены гистограммы выборок разного объёма совместно с теоретическими кривыми.




Рис. 1: Нормальное распределение $N(0, 1)$. При увеличении n гистограмма становится более похожей на плотность распределения.




Рис. 2: Распределение Коши $C(0, 1)$. Из-за тяжёлых хвостов даже при $n = 1000$ могут появляться выбросы, искажающие гистограмму. Сходимость медленная.




Рис. 3: Распределение Лапласа $L(0, 1/\sqrt{2})$. При увеличении n гистограмма становится более похожей на плотность распределения.




Рис. 4: Распределение Пуассона $P(10)$. При малых n ($n = 10$) ступеньки сильно отличаются от теоретических вероятностей; при $n = 100$ соответствие улучшается; при $n = 1000$ гистограмма намного лучше повторяет теоретические значения.




Рис. 5: Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$. Уже при $n = 100$ гистограмма близка к прямоугольной форме; при $n = 1000$ границы определяются достаточно чётко.

5 Обсуждение

В ходе выполнения лабораторной работы были сгенерированы выборки объёмом $n = 10, 100, 1000$ для пяти распределений: нормального, Коши, Лапласа, Пуассона и равномерного. Для каждой выборки построены гистограммы, совмещённые с теоретическими кривыми плотности. Анализ полученных графиков (рис. 1–5) позволяет сделать следующие наблюдения.

Влияние объёма выборки. Для всех распределений с увеличением n гистограмма становится более гладкой и приближается к теоретической кривой. При $n = 10$ форма гистограммы сильно зависит от случайности и может существенно отличаться от ожидаемой. При $n = 100$ уже проявляются характерные черты распределения, а при $n = 1000$ гистограмма практически совпадает с теоретической кривой. Это демонстрирует состоятельность гистограммы как оценки плотности распределения.

Особенности различных распределений.

- **Нормальное распределение** $N(0, 1)$: быстро сходится, уже при $n = 100$ форма близка к колоколообразной, при $n = 1000$ отличия минимальны.
- **Распределение Лапласа** $L(0, 1/\sqrt{2})$: также хорошо аппроксимируется, острый пик в нуле становится заметен при $n \geq 100$.
- **Равномерное распределение** $U(-\sqrt{3}, \sqrt{3})$: при $n = 100$ границы интервала определяются достаточно чётко, при $n = 1000$ прямоугольная форма почти совпадает с теорией.
- **Распределение Пуассона** $P(10)$: дискретность сохраняется при любом n , но относительные частоты при $n = 1000$ очень близки к теоретическим вероятностям; при $n = 10$ возможны значительные отклонения из-за малого числа наблюдений.
- **Распределение Коши** $C(0, 1)$: С ростом n форма пика в окрестности нуля становится более отчётливой, хотя сходимость медленнее, чем у распределений с экспоненциально убывающими хвостами.

Выбор числа интервалов гистограммы. В работе использовались различные стратегии выбора числа бинов в зависимости от типа распределения и объёма выборки. Для большинства непрерывных распределений при $n \leq 100$ применялось правило $\sqrt{n}$ (параметр `'sqrt'`), обеспечивающее достаточную гладкость при малом объёме данных. При $n = 1000$ использовалось адаптивное правило Фридмана–Дьякониса (`'auto'`), которое минимизирует среднеквадратичную ошибку оценки плотности. Для Пуассона при малых n также применялся автоматический подбор бинов, а при $n = 1000$ — фиксированные бины шириной 1. Такой подход позволил получить наглядные и информативные графики для всех случаев.

Таким образом, полученные результаты полностью соответствуют теоретическим представлениям математической статистики о поведении эмпирических оценок плотности и демонстрируют важность адаптации параметров визуализации к свойствам распределения и объёму выборки.

6 Выводы

В ходе лабораторной работы были выполнены все поставленные задачи:

1. **Сгенерированы выборки** объёмом $n = 10, 100, 1000$ для пяти заданных распределений.

2. Построены гистограммы с наложенными теоретическими кривыми плотности, что позволило визуально оценить степень соответствия.
3. Проведён анализ влияния размера выборки на вид гистограммы:
 - При малых n гистограмма может не отражать истинную форму распределения.
 - С увеличением n гистограмма стабилизируется и приближается к теоретической кривой, что подтверждает состоятельность гистограммы как оценки плотности.
 - Скорость сходимости зависит от типа распределения: для распределений с лёгкими хвостами (нормальное, Лапласа, равномерное) она выше, для распределения Коши — ниже из-за влияния редких, но больших выбросов.
 - Для дискретного распределения Пуассона гистограмма при $n = 1000$ практически совпадает с теоретическими вероятностями, демонстрируя закон больших чисел.

Итоговый вывод. Размер выборки критически важен для определения характера распределения с помощью гистограммы. При недостаточном объёме данных можно сделать ошибочные выводы о форме распределения, тогда как при достаточно большом n гистограмма даёт надёжное представление о законе распределения случайной величины.

7 Список литературы

1. Кобзарь А.И. Прикладная математическая статистика. — М.: Физматлит, 2006.
2. Боровков А.А. Математическая статистика. — М.: Наука, 1984.
3. Документация библиотек Numpy и SciPy — <https://docs.scipy.org/doc/>
4. Документация Matplotlib — <https://matplotlib.org/stable/contents.html>

8 Приложение

Ссылка на репозиторий с исходным кодом: <https://github.com/zhitkovns/matstat>