

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Направление подготовки
"01.03.02. Прикладная математика и информатика"

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №2
"Характеристики положения и рассеяния"

Работу
выполнил:
Житков Н. С.
Группа:
5030102/30201

Санкт-Петербург
2026

Содержание

1	Постановка задачи	3
2	Теоретическая часть	3
3	Реализация	4
4	Результаты	5
5	Обсуждение	6
6	Выводы	7
7	Список литературы	8
8	Приложение	8

1 Постановка задачи

Цель работы: исследовать сходимость выборочных характеристик положения к теоретическим значениям при увеличении объёма выборки, а также оценить их устойчивость к наличию выбросов.

Задачи:

- Сгенерировать выборки объёмом $n = 10, 100, 1000$ для пяти распределений:
 1. Нормальное $N(0, 1)$;
 2. Коши $C(0, 1)$;
 3. Лапласа $L(0, 1/\sqrt{2})$;
 4. Пуассона $P(5)$;
 5. Равномерное $U(-\sqrt{3}, \sqrt{3})$.
- Для каждой выборки вычислить пять характеристик положения:
 - выборочное среднее $\bar{x}$;
 - медиану med ;
 - полусумму экстремальных элементов $z_R = (x_{\min} + x_{\max})/2$;
 - полусумму квартилей $z_Q = (Q_{1/4} + Q_{3/4})/2$;
 - усечённое среднее z_{tr} (отбрасывание 10% наименьших и наибольших значений).
- Повторить генерацию и вычисления 1000 раз, найти для каждой характеристики среднее значение $E(z)$ и дисперсию $D(z)$ (по формулам $E(z) = \bar{z}$, $D(z) = \overline{z^2} - (\bar{z})^2$).
- Представить результаты в виде $E(z) \pm \sqrt{D(z)}$ с округлением до одного знака после запятой согласно указанию ($k = 1$).
- Проанализировать поведение оценок при разных n и для разных распределений, обращая особое внимание на устойчивость к выбросам.

2 Теоретическая часть

Характеристики положения

Для описания центра распределения используют различные статистики:

- **Выборочное среднее** $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ — классическая оценка математического ожидания. Чувствительно к выбросам.
- **Медиана** — значение, делящее упорядоченную выборку пополам. Устойчивая оценка, мало подверженная влиянию аномальных наблюдений.
- **Полусумма экстремумов** z_R — среднее арифметическое минимального и максимального элементов. Крайне чувствительна к выбросам.
- **Полусумма квартилей** z_Q — среднее между первым и третьим квартилями. Также устойчива, так как опирается на центральную половину данных.
- **Усечённое среднее** z_{tr} — среднее после отбрасывания заданной доли наименьших и наибольших значений (здесь 10% с каждого конца). Компромисс между эффективностью и устойчивостью.

Квартили и их вычисление

Квартили — это значения, которые делят упорядоченную выборку на четыре равные по объёму части. Первый квартиль $Q_{1/4}$ — это такое значение, что не более 25% наблюдений меньше его и не более 75% больше. Третий квартиль $Q_{3/4}$ определяется аналогично: не более 75% наблюдений меньше его и не более 25% больше. Существует несколько способов вычисления квартилей (например, метод ближайшей позиции, линейная интерполяция и др.). В данной работе используется метод, реализованный в функции `numpy.percentile` с параметром линейной интерполяции (по умолчанию). Для выборки объёма n сначала вычисляется позиция $p = k \cdot (n - 1) + 1$, где $k = 0.25$ для первого квартиля и $k = 0.75$ для третьего. Затем квартиль находится как взвешенная сумма между элементами с индексами $\lfloor p \rfloor$ и $\lceil p \rceil$:

$$Q = x_{\lfloor p \rfloor} + (p - \lfloor p \rfloor) \cdot (x_{\lceil p \rceil} - x_{\lfloor p \rfloor}),$$

где $x_{(i)}$ — i -я порядковая статистика (элементы выборки, упорядоченные по возрастанию). Полусумма квартилей z_Q определяется как среднее арифметическое полученных значений:

$$z_Q = \frac{Q_{1/4} + Q_{3/4}}{2}.$$

Устойчивость оценок

Под устойчивостью понимают способность оценки сохранять своё значение при небольших отклонениях от предполагаемой модели или при наличии редких, но больших выбросов. Среднее арифметическое не является устойчивым — одно аномальное значение может сильно сместить оценку. Медиана и усечённое среднее, напротив, остаются стабильными. Для распределений с тяжёлыми хвостами (например, Коши) среднее теряет состоятельность, тогда как медиана продолжает хорошо оценивать центр.

Правило округления

В лабораторной работе используется следующее правило представления результатов:

$$x = E(z) \pm \sqrt{D(z)},$$

причём первая цифра после десятичной точки считается вариабельной. Для упрощения округление проводится для $k = 1$, т.е. все значения $E(z)$ и $\sqrt{D(z)}$ округляются до одного знака после запятой. Это даёт представление о порядке величины и точности оценок.

3 Реализация

Язык программирования: Python 3.13

Среда разработки: VS Code

Библиотеки:

- `numpy` — генерация выборок и вычисления;
- `csv` — сохранение результатов в табличный файл.

Алгоритм программы:

1. Для каждого из пяти распределений и каждого объёма выборки $n = 10, 100, 1000$ выполняется 1000 итераций:

- генерируется выборка заданного объёма с помощью соответствующего генератора (нормальное: `normal`, Коши: `standard_cauchy`, Лапласа: `laplace` с масштабом $1/\sqrt{2}$, Пуассона: `poisson(5)`, равномерное: `uniform` на $[-\sqrt{3}, \sqrt{3}]$;
 - для каждой выборки вычисляются пять характеристик положения с использованием функций `np.mean`, `np.median`, `np.percentile` и ручной реализации усечённого среднего (сортировка и удаление крайних 10%).
2. Для каждой статистики по 1000 реализациям вычисляются среднее $E(z)$ и дисперсия $D(z)$ (с параметром `ddof=0`, т.е. генеральная дисперсия).
 3. Результаты округляются до одного знака после запятой и записываются в CSV-файл с разделителем «;». Файл содержит столбцы: распределение, объём выборки, статистика, $E(z)$, $\sqrt{D(z)}$.

Вся числовая информация сохраняется в файл `results.csv`.

4 Результаты

Ниже приведены таблицы с оценками $E(z)$ и $\sqrt{D(z)}$ для каждого распределения и каждого объёма выборки. Все значения округлены до одного десятичного знака и соответствуют данным, полученным в ходе эксперимента.

Нормальное распределение

Статистика	$n = 10$		$n = 100$		$n = 1000$	
	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$
Среднее	0.0	0.3	0.0	0.1	0.0	0.0
Медиана	0.0	0.4	0.0	0.1	0.0	0.0
z_R	0.0	0.4	0.0	0.3	0.0	0.3
z_Q	0.0	0.3	0.0	0.1	0.0	0.0
Усечённое среднее	0.0	0.3	0.0	0.1	0.0	0.0

Таблица 1: Характеристики положения для нормального распределения

Распределение Коши

Статистика	$n = 10$		$n = 100$		$n = 1000$	
	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$
Среднее	3.0	64.9	2.0	55.8	0.1	15.2
Медиана	0.0	0.6	0.0	0.2	0.0	0.1
z_R	14.8	324.4	97.1	2785.4	22.2	7412.3
z_Q	0.0	1.0	0.0	0.2	0.0	0.1
Усечённое среднее	0.1	1.3	0.0	0.2	0.0	0.1

Таблица 2: Характеристики положения для распределения Коши

Распределение Лапласа

Статистика	$n = 10$		$n = 100$		$n = 1000$	
	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$
Среднее	0.0	0.3	0.0	0.1	0.0	0.0
Медиана	0.0	0.3	0.0	0.1	0.0	0.0
z_R	0.0	0.6	0.0	0.6	0.0	0.7
z_Q	0.0	0.3	0.0	0.1	0.0	0.0
Усечённое среднее	0.0	0.3	0.0	0.1	0.0	0.0

Таблица 3: Характеристики положения для распределения Лапласа

Распределение Пуассона

Статистика	$n = 10$		$n = 100$		$n = 1000$	
	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$
Среднее	5.0	0.7	5.0	0.2	5.0	0.1
Медиана	4.8	0.9	4.9	0.3	5.0	0.0
z_R	5.3	1.0	6.0	0.7	6.8	0.6
z_Q	4.9	0.8	4.9	0.4	4.7	0.3
Усечённое среднее	4.9	0.7	4.9	0.2	4.9	0.1

Таблица 4: Характеристики положения для распределения Пуассона

Равномерное распределение

Статистика	$n = 10$		$n = 100$		$n = 1000$	
	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$
Среднее	0.0	0.3	0.0	0.1	0.0	0.0
Медиана	0.0	0.5	0.0	0.2	0.0	0.1
z_R	0.0	0.2	0.0	0.0	0.0	0.0
z_Q	0.0	0.4	0.0	0.1	0.0	0.0
Усечённое среднее	0.0	0.4	0.0	0.1	0.0	0.0

Таблица 5: Характеристики положения для равномерного распределения

5 Обсуждение

Сходимость при увеличении n

Для всех распределений с ростом объёма выборки среднееквадратичное отклонение ($\sqrt{D(z)}$) каждой оценки уменьшается, что свидетельствует о состоятельности рассматриваемых статистик (кроме среднего для распределения Коши). Для нормального, лапласовского и равномерного распределений уже при $n = 100$ разброс большинства оценок становится малым, а при $n = 1000$ среднее, медиана, полусумма квартилей и усечённое среднее имеют $\sqrt{D(z)} \leq 0.1$ (для нормального и лапласовского часто $\sqrt{D(z)} = 0.0$ после округления). Полусумма экстремумов z_R даже при $n = 1000$ сохраняет заметный разброс: для нормального $\sqrt{D(z_R)} = 0.3$, для лапласовского 0.7, что связано с медленной сходимостью крайних порядковых статистик.

Для равномерного распределения, напротив, z_R при $n = 1000$ имеет нулевой разброс, так как минимум и максимум выборки практически достигают теоретических границ интервала.

Устойчивость к выбросам

Наиболее ярко устойчивость проявляется в распределении Коши. Выборочное среднее здесь ведёт себя крайне нестабильно: даже при $n = 1000$ его стандартное отклонение остаётся огромным (15.2), а при $n = 10$ оно достигает 64.9, что делает среднее бесполезной характеристикой центра. Медиана, полусумма квартилей и усечённое среднее, напротив, сохраняют малый разброс: при $n = 1000$ их $\sqrt{D(z)}$ составляет всего 0.1, а средние значения близки к истинному центру (нулю). Полусумма экстремумов z_R также крайне чувствительна к выбросам — её дисперсия для Коши колоссальна (при $n = 1000$ $\sqrt{D(z_R)} = 7412.3$).

Для распределений без тяжёлых хвостов (нормальное, Лапласа, равномерное) разница между устойчивыми и неустойчивыми оценками менее выражена, однако z_R всё же проигрывает по эффективности (большой разброс). Медиана и усечённое среднее показывают практически такую же точность, как и обычное среднее, что говорит об их хорошей эффективности для симметричных распределений.

Особенности дискретного распределения (Пуассон)

Для распределения Пуассона (среднее 5) все оценки, кроме z_R , достаточно хорошо оценивают центр. Полусумма экстремумов систематически смещена вверх: при $n = 10$ $E(z_R) = 5.3$, при $n = 1000$ $E(z_R) = 6.8$. Это объясняется тем, что максимум пуассоновской выборки часто превышает среднее, а минимум ограничен нулём. С ростом n смещение уменьшается, но остаётся заметным. Обращает на себя внимание полусумма квартилей z_Q : при $n = 1000$ $E(z_Q) = 4.7$ при $\sqrt{D(z_Q)} = 0.3$, что немного ниже теоретического значения 5. Это может быть связано с асимметрией распределения Пуассона и особенностями вычисления квартилей, но в целом результат лежит в пределах статистической погрешности.

Округление

Представление результатов с одним знаком после запятой ($0.0 \pm 0.1k$ при $k = 1$) позволяет наглядно сравнить порядок величин и точность оценок. Для распределения Коши среднее и z_R пришлось оставить с большими числами, так как их разброс огромен, что, однако, соответствует реальной ситуации.

6 Выводы

В ходе лабораторной работы были выполнены все поставленные задачи:

1. Сгенерированы выборки объёмом 10, 100 и 1000 для пяти различных распределений.
2. Для каждой выборки вычислены пять характеристик положения.
3. Проведён статистический эксперимент (1000 повторений), позволивший оценить математическое ожидание и дисперсию каждой характеристики.
4. Полученные результаты подтвердили теоретические представления о поведении оценок:

- Для распределений с конечной дисперсией (нормальное, Лапласа, равномерное) все пять оценок состоятельны — с ростом объёма выборки они сходятся к истинному центру. При $n = 1000$ среднее, медиана, полусумма квартилей и усечённое среднее имеют пренебрежимо малый разброс ($\sqrt{D(z)} \leq 0.1$), тогда как полусумма экстремумов z_R сходится медленнее (её разброс остаётся заметным). Для распределения Коши выборочное среднее и z_R не являются состоятельными: их дисперсия не убывает с ростом n (при $n = 1000$ $\sqrt{D(\bar{x})} = 15.2$, $\sqrt{D(z_R)} = 7412.3$), тогда как медиана, z_Q и усечённое среднее сохраняют состоятельность и малый разброс ($\sqrt{D} \approx 0.1$).
- Среднее арифметическое оказалось крайне неустойчивым для распределения Коши: его стандартное отклонение при $n = 1000$ составляет 15.2, тогда как медиана, полусумма квартилей и усечённое среднее сохраняют разброс на уровне 0.1. Полусумма экстремумов z_R для Коши имеет колоссальный разброс (тысячи), что делает её полностью непригодной для практического использования.
- Для распределения Пуассона наблюдается систематическое смещение полусуммы экстремумов вверх (от 5.3 при $n = 10$ до 6.8 при $n = 1000$), в то время как остальные характеристики достаточно точно оценивают параметр $\lambda = 5$. Полусумма квартилей при $n = 1000$ даёт 4.7, что несколько ниже теоретического значения, но укладывается в пределы статистической погрешности с учётом асимметрии распределения.
- Усечённое среднее продемонстрировало хороший баланс между устойчивостью и эффективностью, приближаясь по точности к обычному среднему для распределений с лёгкими хвостами и значительно превосходя его для распределения Коши.

Таким образом, выбор подходящей характеристики положения должен основываться на априорной информации о наличии выбросов и типе распределения данных. Устойчивые оценки (медиана, усечённое среднее) являются предпочтительными в ситуациях, где возможны аномальные наблюдения.

7 Список литературы

1. Кобзарь А.И. Прикладная математическая статистика. — М.: Физматлит, 2006.
2. Боровков А.А. Математическая статистика. — М.: Наука, 1984.
3. Документация библиотеки NumPy — <https://numpy.org/doc/>

8 Приложение

Ссылка на репозиторий с исходным кодом: <https://github.com/zhitkovns/matstat/tree/lab2>