

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Направление подготовки
"01.03.02. Прикладная математика и информатика"

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №3
"Боксплот Тьюки и анализ выбросов"

Работу
выполнил:
Житков Н. С.
Группа:
5030102/30201

Санкт-Петербург
2026

Содержание

1	Постановка задачи	3
2	Теоретическая часть	3
3	Реализация	5
4	Результаты	5
5	Обсуждение	7
6	Выводы	8
7	Список литературы	9
8	Приложение	9

1 Постановка задачи

Цель работы: научиться применять боксплот Тьюки для анализа одномерных распределений и исследовать влияние объёма выборки на долю обнаруживаемых выбросов.

Задачи:

- Сгенерировать выборки объёмом $n = 20$ и $n = 100$ для пяти распределений:
 1. Нормальное $N(0, 1)$;
 2. Коши $C(0, 1)$;
 3. Лапласа $L(0, 1/\sqrt{2})$;
 4. Пуассона $P(5)$;
 5. Равномерное $U(-\sqrt{3}, \sqrt{3})$.
- Для каждой выборки построить боксплот Тьюки.
- Провести 1000 экспериментов для каждого распределения и каждого объёма, вычислить среднюю долю выбросов (отношение числа выбросов к объёму выборки).
- Сравнить полученные доли выбросов с теоретическими ожиданиями и проанализировать влияние размера выборки.

2 Теоретическая часть

Квантили и межквартильный размах (IQR)

Для описания распределения данных часто используют квантили — значения, делящие упорядоченную выборку на равные части. В боксплоте применяются три основных квартиля:

- **Первый квартиль** Q_1 — значение, ниже которого находится ровно 25% наблюдений.
- **Второй квартиль** Q_2 (медиана) — значение, которое делит выборку пополам: 50% данных меньше медианы, 50% — больше.
- **Третий квартиль** Q_3 — значение, ниже которого находится 75% данных.

Межквартильный размах (IQR, interquartile range) определяется как разность третьего и первого квартилей:

$$IQR = Q_3 - Q_1.$$

Он характеризует разброс «средней половины» данных (от Q_1 до Q_3) и, в отличие от стандартного отклонения, является устойчивой мерой рассеяния, так как не подвержен влиянию экстремальных значений.

Боксплот Тьюки: элементы и их интерпретация

Боксплот (ящик с усами) — это компактный графический способ визуализации одномерного распределения. Он строится на основе пяти сводных статистик: минимума (в пределах усов), Q_1 , медианы, Q_3 и максимума (в пределах усов), а также отображает возможные выбросы. Рассмотрим его составные части.

- **Ящик (box)** — прямоугольник, простирающийся от первого квартиля Q_1 до третьего квартиля Q_3 . Длина ящика равна межквартильному размаху IQR и показывает разброс центральных 50% данных. Внутри ящика линией отмечена медиана. По положению медианы относительно границ ящика можно судить об асимметрии распределения: если медиана ближе к Q_1 , распределение имеет положительную скошенность (правый хвост), если ближе к Q_3 — отрицательную скошенность (левый хвост).
- **Усы (whiskers)** — отрезки, выходящие из ящика к крайним наблюдениям, которые не считаются выбросами. Нижний ус тянется до наименьшего значения, не меньшего чем $Q_1 - 1,5 \cdot IQR$, а верхний ус — до наибольшего значения, не превышающего $Q_3 + 1,5 \cdot IQR$. Усы демонстрируют размах данных за пределами центральной половины, исключая аномальные значения.
- **Выбросы (outliers)** — индивидуальные точки, расположенные за пределами усов. Они соответствуют наблюдениям, попадающим в интервалы $(-\infty, Q_1 - 1,5 \cdot IQR)$ или $(Q_3 + 1,5 \cdot IQR, +\infty)$. Такие значения требуют особого внимания, поскольку могут быть следствием ошибок измерения, уникальных условий или указывать на наличие редких событий.

Правило идентификации выбросов

Наблюдение считается потенциальным выбросом, если его значение выходит за интервал

$$[Q_1 - 1,5 \cdot IQR, Q_3 + 1,5 \cdot IQR].$$

Исследуемые распределения

1. **Нормальное распределение** $N(0, 1)$:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad MX = 0, \quad DX = 1.$$

2. **Распределение Коши** $C(0, 1)$:

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad \text{моменты не определены.}$$

3. **Распределение Лапласа** $L(0, 1/\sqrt{2})$:

$$f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}, \quad MX = 0, \quad DX = 1.$$

4. **Распределение Пуассона** $P(5)$:

$$P(X = k) = \frac{5^k e^{-5}}{k!}, \quad k = 0, 1, 2, \dots, \quad MX = 5, \quad DX = 5.$$

5. **Равномерное распределение** $U(-\sqrt{3}, \sqrt{3})$:

$$f(x) = \frac{1}{2\sqrt{3}}, \quad |x| \leq \sqrt{3}, \quad MX = 0, \quad DX = 1.$$

3 Реализация

Язык программирования: Python 3.13

Среда разработки: VS Code

Библиотеки:

- `numpy` — генерация выборок и вычисления;
- `matplotlib.pyplot` — построение боксплотов;
- `csv` — сохранение результатов.

Алгоритм программы:

1. Для каждого распределения и каждого объёма выборки ($n = 20, 100$) выполняется 1000 итераций:
 - генерируется выборка заданного объёма;
 - вычисляются первый и третий квартили, межквартильный размах;
 - определяется доля элементов, выходящих за границы $[Q_1 - 1.5IQR, Q_3 + 1.5IQR]$.
2. Доли усредняются по 1000 экспериментам и записываются в CSV-файл.
3. Для последней сгенерированной выборки каждого типа строится боксплот и сохраняется в виде изображения.

Все численные результаты сохраняются в файл `results/outlier_fractions.csv`, графики — в папку `images/`.

4 Результаты

Боксплоты

На рисунках 1–5 представлены боксплоты для выборок объёмом $n = 20$ и $n = 100$ для каждого распределения. Красными точками отмечены выбросы.




Рис. 1: Боксплоты для нормального распределения




Рис. 2: Боксплоты для распределения Коши




Рис. 3: Боксплоты для распределения Лапласа




Рис. 4: Боксплоты для распределения Пуассона




Рис. 5: Боксплоты для равномерного распределения

Экспериментальная оценка доли выбросов

Для иллюстрации правила $[Q_1 - 1,5 \cdot IQR, Q_3 + 1,5 \cdot IQR]$ был проведён вычислительный эксперимент. Для пяти распределений (нормального, Коши, Лапласа, Пуассона и равномерного) генерировалось по 1000 выборок объёма $n = 20$ и $n = 100$. Для каждой выборки вычислялась доля наблюдений, попадающих в область выбросов (за пределы усов Тьюки), после чего результаты усреднялись. Полученные средние доли представлены в таблице 1.

Распределение	$n = 20$	$n = 100$
Нормальное	0.0241	0.0098
Коши	0.1482	0.1552
Лапласа	0.0739	0.0666
Пуассона	0.0246	0.0145
Равномерное	0.0027	0.0000

Таблица 1: Средняя доля выбросов по правилу Тьюки

5 Обсуждение

Анализ боксплотов

Визуальный анализ боксплотов (рис. 1–5) подтверждает теоретические свойства распределений:

- **Нормальное распределение:** медиана расположена примерно в центре ящика, усы примерно одинаковой длины. Выбросы встречаются редко, что соответствует малой доле экстремальных значений.
- **Распределение Коши** характеризуется большим числом выбросов даже при небольших объёмах выборки. Это следствие тяжёлых хвостов, из-за которых экстремальные значения появляются часто.
- **Распределение Лапласа:** хвосты тяжелее, чем у нормального распределения, поэтому количество выбросов заметно выше.
- **Распределение Пуассона** при $n = 20$ может выглядеть асимметрично (скошенность вправо), а при $n = 100$ уже симметрично.
- **Равномерное распределение:** практически не имеет выбросов, и лишь при малых выборках случайно могут появляться значения, формально попадающие в категорию выбросов.

Сравнение долей выбросов

Из таблицы 1 видно:

- Для **нормального распределения** средняя доля выбросов при $n = 20$ составляет 2.41%, а при $n = 100$ — 0.98%. Теоретическое значение для нормального распределения составляет около 0.7%. При $n = 100$ результат уже близок к этой величине, а при $n = 20$ оценка несколько завышена из-за большей изменчивости выборочных квартилей.

- Для **распределения Коши** доля выбросов очень велика: 14.8% при $n = 20$ и 15.5% при $n = 100$. Теоретическая доля выбросов для стандартного распределения Коши составляет примерно 15.6%, что хорошо согласуется с экспериментальными данными. Это объясняется тяжёлыми хвостами — даже в небольших выборках часто встречаются значения, далеко выходящие за пределы межквартильного размаха.
- **Распределение Лапласа** даёт промежуточный результат: 7.4% при $n = 20$ и 6.7% при $n = 100$. Теоретическое значение для этого распределения (с параметром масштаба $1/\sqrt{2}$) составляет около 6.25%. Экспериментальные оценки близки к теоретической, особенно при $n = 100$. Хвосты Лапласа убывают медленнее, чем у нормального, но быстрее, чем у Коши, что и определяет долю выбросов.
- Для **распределения Пуассона** доля выбросов при $n = 20$ составляет 2.46%, при $n = 100$ — 1.45%. Теоретическая вероятность с параметром $\lambda = 5$ равна примерно 1.37%. С ростом объёма выборки оценка приближается к этому значению; при $n = 20$ наблюдается завышение из-за малого объёма данных и дискретности.
- **Равномерное распределение** практически не даёт выбросов: при $n = 20$ доля равна 0.27%, а при $n = 100$ — 0.00%. Теоретическая доля выбросов на отрезке $[-\sqrt{3}, \sqrt{3}]$ равна нулю, так как границы Тьюки (-3.46 и 3.46) лежат далеко за пределами носителя. Небольшое положительное значение при $n = 20$ объясняется случайными флуктуациями крайних значений.

Влияние объёма выборки

При увеличении объёма выборки n средняя доля выбросов стабилизируется и стремится к некоторой константе, характерной для данного распределения. Для распределений с конечными моментами эта доля практически не меняется при переходе от $n = 20$ к $n = 100$, что подтверждает её статус характеристики распределения, а не конкретной выборки. Для распределения Коши, несмотря на сильную изменчивость, доля также остаётся примерно постоянной. Для Пуассона небольшое уменьшение доли с ростом n может объясняться лучшей аппроксимацией непрерывного правила Тьюки для дискретных данных при увеличении объёма.

6 Выводы

В ходе выполнения лабораторной работы были решены все поставленные задачи:

1. Сгенерированы выборки объёмом $n = 20$ и $n = 100$ для пяти распределений.
2. Для каждой выборки построены боксплоты Тьюки, наглядно демонстрирующие разброс данных, положение медианы, квартилей и наличие выбросов.
3. На основе 1000 повторений для каждого распределения и объёма вычислены средние доли наблюдений, попадающих в категорию выбросов по правилу $[Q_1 - 1.5 IQR, Q_3 + 1.5 IQR]$.
4. Полученные результаты хорошо согласуются с теоретическими представлениями:
 - Для нормального распределения средняя доля выбросов составила 2.41% при $n = 20$ и 0.98% при $n = 100$, что близко к теоретическому значению 0.7%.
 - Наибольшая доля выбросов зафиксирована для распределения Коши ($\approx 15\%$), что обусловлено его тяжёлыми хвостами.

- Для распределения Лапласа доля выбросов составляет около 7%.
 - Распределение Пуассона даёт долю выбросов порядка 1.5%–2.5%, что связано с дискретностью и асимметрией.
 - Равномерное распределение практически не порождает выбросов (менее 0.3%), что соответствует его ограниченному носителю.
5. Объём выборки не оказывает принципиального влияния на среднюю долю выбросов (она является характеристикой распределения), однако при малых n наблюдается большая изменчивость оценки, что особенно заметно для нормального распределения при $n = 20$.

Таким образом, боксплот Тьюки является эффективным инструментом первичного анализа данных, позволяющим быстро оценить симметрию, разброс и наличие аномальных наблюдений, а правило $1.5 IQR$ даёт разумную границу для идентификации выбросов, чувствительную к форме распределения.

7 Список литературы

1. Кобзарь А.И. "Прикладная математическая статистика."— М.: Физматлит, 2006.
2. Тьюки Дж. "Анализ результатов наблюдений."— М.: Мир, 1981.
3. Документация библиотек NumPy и Matplotlib: <https://docs.scipy.org/doc/>, <https://matplotlib.org/stable/contents.html>

8 Приложение

Ссылка на репозиторий с исходным кодом: <https://github.com/zhitkovns/matstat/tree/lab3>