

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Направление подготовки
"01.03.02. Прикладная математика и информатика"

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №4
"Эмпирическая функция распределения и ядерные оценки плотности"

Работу
выполнил:
Житков Н. С.
Группа:
5030102/30201

Санкт-Петербург
2026

Содержание

1	Постановка задачи	3
2	Теоретическая часть	3
3	Реализация	5
4	Результаты	5
5	Обсуждение	8
6	Выводы	9
7	Список литературы	10
8	Приложение	10

1 Постановка задачи

Цель работы: изучить два способа оценки функции распределения и плотности вероятности – эмпирическую функцию распределения и ядерную оценку плотности, а также исследовать влияние объёма выборки на качество приближения к теоретическим кривым.

Задачи:

- Сгенерировать выборки объёмом $n = 20, 60, 100$ для пяти распределений:
 1. Нормальное $N(0, 1)$;
 2. Коши $C(0, 1)$;
 3. Лапласа $L(0, 1/\sqrt{2})$;
 4. Пуассона $P(5)$;
 5. Равномерное $U(-\sqrt{3}, \sqrt{3})$.
- Для каждой выборки построить эмпирическую функцию распределения и наложить на неё теоретическую функцию распределения.
- Для каждой выборки построить ядерную оценку плотности и наложить теоретическую плотность.
- Для непрерывных распределений графики строить на отрезке $[-4, 4]$, для распределения Пуассона – на отрезке $[6, 14]$ (чтобы охватить область, где сосредоточена основная масса вероятности).
- Сравнить полученные оценки при разных объёмах выборки и сделать выводы о сходимости эмпирической функции распределения и ядерной оценки плотности к истинным характеристикам.

2 Теоретическая часть

Эмпирическая функция распределения

Пусть $X_1, \dots, X_n$ – независимые одинаково распределённые случайные величины с функцией распределения $F(x)$. Эмпирическая функция распределения определяется как

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{I}_{\{X_i \leq x\}},$$

где $\mathbf{I}$ – индикатор. Для каждого фиксированного x величина $\hat{F}_n(x)$ является несмещённой и состоятельной оценкой $F(x)$. Более того, согласно теореме Гливенко–Кантелли,

$$\sup_{x \in R} |\hat{F}_n(x) - F(x)| \xrightarrow[n \rightarrow \infty]{\text{п.н.}} 0,$$

т.е. эмпирическая функция распределения равномерно сходится к теоретической почти наверное.

Ядерная оценка плотности

Гистограмма – простейшая оценка плотности, но она является ступенчатой и чувствительна к выбору числа интервалов. Ядерная оценка плотности лишена этих недостатков и даёт гладкую кривую. Она имеет вид

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right),$$

где K – ядро (неотрицательная функция, интегрируемая с единицей), а $h > 0$ – параметр сглаживания (ширина окна). В работе используется гауссово ядро $K(u) = \frac{1}{\sqrt{2\pi}}e^{-u^2/2}$. Параметр h выбирается автоматически; в данной работе применяется метод Сильвермана (Silverman's rule of thumb), реализованный в функции `scipy.stats.gaussian_kde` при указании параметра `bw_method='silverman'`.

Выбор параметра сглаживания

Качество ядерной оценки существенно зависит от выбора ширины окна h . Слишком малое h приводит к появлению ложных пиков (переобучение), слишком большое — к чрезмерному сглаживанию и потере деталей (смещение). Метод Сильвермана основан на предположении, что истинное распределение близко к нормальному, и минимизирует среднеквадратичную ошибку. Для одномерного случая оптимальная ширина окна приближённо равна

$$h = \left(\frac{4\hat{\sigma}^5}{3n}\right)^{1/5},$$

где $\hat{\sigma}$ — выборочное стандартное отклонение. На практике вместо $\hat{\sigma}$ часто используют более устойчивую оценку разброса — межквартильный размах (IQR):

$$\hat{\sigma} = \min\left(\hat{\sigma}, \frac{IQR}{1.34}\right).$$

Такая корректировка делает метод более робастным к выбросам и позволяет получать приемлемые результаты даже для распределений, заметно отличающихся от нормального, что особенно важно при анализе распределений с тяжёлыми хвостами (например, Коши) или при наличии аномальных наблюдений.

Исследуемые распределения

1. Нормальное распределение $N(0, 1)$:

$$f(x) = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}, \quad F(x) = \Phi(x).$$

2. Распределение Коши $C(0, 1)$:

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad F(x) = \frac{1}{\pi} \arctan x + \frac{1}{2}.$$

3. Распределение Лапласа $L(0, 1/\sqrt{2})$:

$$f(x) = \frac{1}{\sqrt{2}}e^{-\sqrt{2}|x|}, \quad F(x) = \begin{cases} \frac{1}{2}e^{\sqrt{2}x}, & x \leq 0, \\ 1 - \frac{1}{2}e^{-\sqrt{2}x}, & x > 0. \end{cases}$$

4. Распределение Пуассона $P(5)$:

$$P(X = k) = \frac{5^k e^{-5}}{k!}, \quad k = 0, 1, 2, \dots, \quad F(x) = \sum_{k \leq x} \frac{5^k e^{-5}}{k!}.$$

5. Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$:

$$f(x) = \frac{1}{2\sqrt{3}}, \quad |x| \leq \sqrt{3}, \quad F(x) = \frac{x + \sqrt{3}}{2\sqrt{3}}, \quad x \in [-\sqrt{3}, \sqrt{3}].$$

3 Реализация

Язык программирования: Python 3.13

Среда разработки: VS Code

Библиотеки:

- `numpy` – генерация выборок и вычисления;
- `scipy.stats` – теоретические функции распределения и плотности, а также ядерная оценка (`gaussian_kde`);
- `matplotlib.pyplot` – построение графиков.

Алгоритм программы:

1. Для каждого распределения и каждого объёма выборки $n = 20, 60, 100$ генерируется одна реализация случайной выборки.
2. Строится график эмпирической функции распределения (ступенчатая линия) совместно с теоретической функцией распределения.
3. Строится график ядерной оценки плотности (с гауссовым ядром) совместно с теоретической плотностью. Для непрерывных распределений теоретическая плотность изображается сплошной линией, для Пуассона – дискретные вероятности отображаются в виде стержневой диаграммы (`stem`).
4. Все графики сохраняются в папку `images/` с именами, содержащими название распределения и объём выборки.

4 Результаты

На рисунках 1–10 представлены полученные графики для всех распределений и всех объёмов выборок. Для экономии места в отчёте приведены только наиболее показательные комбинации; полный набор изображений доступен в папке `images/`.

Эмпирические функции распределения




Рис. 1: Эмпирическая функция распределения для нормального распределения




Рис. 2: Эмпирическая функция распределения для распределения Коши




Рис. 3: Эмпирическая функция распределения для распределения Лапласа




Рис. 4: Эмпирическая функция распределения для распределения Пуассона




Рис. 5: Эмпирическая функция распределения для равномерного распределения

Ядерные оценки плотности




Рис. 6: Ядерная оценка плотности для нормального распределения




Рис. 7: Ядерная оценка плотности для распределения Коши




Рис. 8: Ядерная оценка плотности для распределения Лапласа




Рис. 9: Ядерная оценка плотности для распределения Пуассона




Рис. 10: Ядерная оценка плотности для равномерного распределения

5 Обсуждение

Сходимость эмпирической функции распределения

Из представленных графиков видно, что с ростом объёма выборки эмпирическая функция распределения всё точнее приближает теоретическую. При $n = 20$ ступенчатая линия ещё заметно отклоняется от гладкой кривой. При $n = 60$ отклонения уменьшаются, а при $n = 100$ эмпирическая и теоретическая функции практически совпадают для всех распределений, включая Коши (несмотря на тяжёлые хвосты, ступеньки хорошо ложатся на теоретическую кривую). Это наглядно демонстрирует теорему Гливенко–Кантелли.

Для дискретного распределения Пуассона эмпирическая функция также хорошо приближает теоретическую, хотя из-за ступенчатой природы обеих функций визуальная разница заметна лишь при малых n .

Ядерные оценки плотности

Ядерная оценка плотности даёт гладкую кривую, которая при увеличении n приближается к теоретической плотности. Для нормального распределения уже при $n = 20$ оценка довольно близка к истинной кривой, а при $n = 100$ практически неотличима. Для распределения Лапласа оценка хорошо воспроизводит острый пик в нуле, хотя при малых выборках может наблюдаться некоторое сглаживание.

Для распределения Коши ядерная оценка при малых n имеет тенденцию к появлению ложных пиков из-за редких выбросов, но с ростом объёма выборки форма приближается к теоретической.

Для равномерного распределения ядерная оценка «размазывает» плотность за пределы интервала $[-\sqrt{3}, \sqrt{3}]$, что является следствием граничного эффекта. При увеличении n этот эффект ослабевает, но полностью не исчезает – ядерное сглаживание всегда даёт ненулевые значения вне носителя, если не использовать специальные граничные поправки.

Для распределения Пуассона ядерная оценка (применённая к дискретным данным) даёт непрерывную кривую, которая при $n = 100$ хорошо огибает теоретические вероятности.

Сравнение с гистограммой

На графиках ядерных оценок для сравнения полупрозрачной заливкой показана гистограмма (с выбором числа бинов из первой лабораторной работы). Видно, что гистограмма является ступенчатой и сильно зависит от числа интервалов, тогда как ядерная оценка гладкая и более устойчива. При малых выборках гистограмма может давать неинформативные пустые бины, в то время как ядерная оценка «заполняет» промежутки, что не всегда желательно (например, для дискретных данных). Таким образом, выбор между гистограммой и ядерной оценкой зависит от целей анализа и предполагаемой природы данных.

6 Выводы

В ходе выполнения лабораторной работы были решены все поставленные задачи:

1. Сгенерированы выборки трёх объёмов ($n = 20, 60, 100$) для пяти распределений: нормального, Коши, Лапласа, Пуассона и равномерного.
2. Для каждой выборки построены графики эмпирической функции распределения и ядерной оценки плотности, совмещённые с теоретическими кривыми.
3. Визуальный анализ графиков подтвердил теоретические результаты:
 - Эмпирическая функция распределения равномерно сходится к теоретической с ростом n (теорема Гливенко–Кантелли).
 - Ядерная оценка плотности при увеличении объёма выборки приближается к истинной плотности, но чувствительна к граничным эффектам и тяжёлым хвостам.
4. Сравнение с гистограммой показало преимущества ядерного сглаживания в получении гладких оценок, но также и его ограничения (например, выход за границы носителя равномерного распределения).

Таким образом, эмпирическая функция распределения и ядерная оценка плотности являются состоятельными и удобными инструментами непараметрического оценивания, применимыми к данным из различных распределений.

7 Список литературы

1. Кобзарь А.И. "Прикладная математическая статистика."— М.: Физматлит, 2006.
2. Скотт Д.У. "Многомерное оценивание плотности: теория, практика и визуализация"— Wiley, 2015.
3. Документация библиотек NumPy, SciPy, Matplotlib: <https://docs.scipy.org/doc/>, <https://matplotlib.org/stable/contents.html>

8 Приложение

Ссылка на репозиторий с исходным кодом: <https://github.com/zhitkovns/matstat/tree/lab4>