

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Направление подготовки
"01.03.02. Прикладная математика и информатика"

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №4
"Эмпирическая функция распределения и ядерные оценки плотности"

Работу
выполнил:
Житков Н. С.
Группа:
5030102/30201

Санкт-Петербург
2026

Содержание

1	Постановка задачи	3
2	Теоретическая часть	3
3	Реализация	6
4	Результаты	7
5	Обсуждение	10
6	Выводы	11
7	Список литературы	12
8	Приложение	12

1 Постановка задачи

Цель работы: изучить два способа оценки функции распределения и плотности вероятности – эмпирическую функцию распределения (ЭФР) и ядерную оценку плотности (KDE), а также исследовать влияние объёма выборки на качество приближения к теоретическим кривым.

Задачи:

- Сгенерировать выборки объёмом $n = 20, 60, 100$ для пяти распределений:
 1. Нормальное $N(0, 1)$;
 2. Коши $C(0, 1)$;
 3. Лапласа $L(0, 1/\sqrt{2})$;
 4. Пуассона $P(5)$;
 5. Равномерное $U(-\sqrt{3}, \sqrt{3})$.
- Для каждой выборки построить эмпирическую функцию распределения, совместив её с теоретической функцией распределения, а также показать ЭФР, полученную из гистограммы (кумулятивную сумму).
- Для каждой выборки построить ядерную оценку плотности (гауссово ядро) и сравнить её с гистограммой и теоретической плотностью.
- Для непрерывных распределений (кроме Коши) графики строить на отрезке $[-4, 4]$; для Коши ввиду тяжёлых хвостов используется отрезок $[-20, 20]$; для распределения Пуассона – отрезок $[0, 10]$, где сосредоточена основная масса вероятности при $\lambda = 5$.
- Дополнительно на примере равномерного и лапласовского распределений ($n = 100$) продемонстрировать влияние ширины окна h_{KDE} на ядерную оценку.
- Сравнить полученные оценки при разных объёмах выборки и сделать выводы о сходимости ЭФР и KDE к истинным характеристикам.

2 Теоретическая часть

Эмпирическая функция распределения

Пусть $X_1, \dots, X_n$ – независимые одинаково распределённые случайные величины с функцией распределения $F(x)$. Эмпирическая функция распределения определяется как

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{X_i \leq x\}}.$$

Для каждого фиксированного x величина $\hat{F}_n(x)$ является несмещённой и состоятельной оценкой $F(x)$. Согласно теореме Гливенко–Кантелли,

$$\sup_{x \in R} |\hat{F}_n(x) - F(x)| \xrightarrow[n \rightarrow \infty]{\text{п.н.}} 0,$$

т.е. эмпирическая функция распределения равномерно сходится к теоретической почти наверное.

Квартили и межквартильный размах (IQR)

Для описания распределения данных часто используют квантили — значения, делящие упорядоченную выборку на равные части. В частности, квартили:

- **Первый квартиль** Q_1 — значение, ниже которого находится ровно 25% наблюдений.
- **Второй квартиль** Q_2 (медиана) — значение, которое делит выборку пополам.
- **Третий квартиль** Q_3 — значение, ниже которого находится 75% данных.

Межквартильный размах (IQR, interquartile range) определяется как разность третьего и первого квартилей:

$$IQR = Q_3 - Q_1.$$

IQR является устойчивой мерой рассеяния, не подверженной влиянию экстремальных значений. Квартили вычисляются по упорядоченной выборке с использованием линейной интерполяции между соседними порядковыми статистиками (метод, реализованный в функции `numpy.percentile`).

Гистограмма и правило Фридмана–Дьякониса

Гистограмма — классический способ оценки плотности. Её качество существенно зависит от выбора ширины интервалов (бинов). Слишком узкие бины приводят к зашумлённой оценке, слишком широкие — к потере деталей. Для автоматического выбора ширины бина используется правило Фридмана–Дьякониса:

$$h_{\text{hist}} = 2 \cdot \frac{IQR}{n^{1/3}},$$

где IQR — межквартильный размах выборки, n — объём выборки. Это правило минимизирует среднеквадратичную ошибку оценки плотности для широкого класса распределений. Число интервалов определяется как

$$k = \left\lceil \frac{\max(x) - \min(x)}{h_{\text{hist}}} \right\rceil.$$

В работе для непрерывных распределений (кроме Коши) гистограммы строятся с использованием этого правила (параметр `bins='fd'` в `matplotlib`).

Ядерная оценка плотности

Ядерная оценка плотности даёт гладкую кривую и имеет вид

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right),$$

где K — ядро (неотрицательная функция, интегрируемая с единицей), а $h > 0$ — параметр сглаживания (ширина окна). В работе используется гауссово ядро $K(u) = \frac{1}{\sqrt{2\pi}} e^{-u^2/2}$. В отличие от библиотечной реализации `scipy.stats.gaussian_kde`, в данной работе ядерная оценка реализована явно в виде функции `gaussian_kde(x, sample, h)`, что даёт полный контроль над параметром h и позволяет легко варьировать его для демонстрации влияния. Чтобы избежать путаницы с шириной бина гистограммы, для ширины окна ядерной оценки будем использовать обозначение h_{KDE} .

Выбор параметра сглаживания: метод Сильвермана

Качество ядерной оценки критически зависит от выбора h_{KDE} . Метод Сильвермана (Silverman's rule of thumb) основан на минимизации среднеквадратичной ошибки для нормального распределения и даёт следующую формулу для оптимальной ширины окна:

$$h_s = \left(\frac{4\hat{\sigma}^5}{3n} \right)^{1/5},$$

где $\hat{\sigma}$ — оценка стандартного отклонения. Для нормального распределения эта формула является асимптотически оптимальной. На практике $\hat{\sigma}$ обычно заменяют выборочным стандартным отклонением s , что приводит к выражению:

$$h_s = 1.06 s n^{-1/5}.$$

Робастная модификация метода Сильвермана

Для распределений с тяжёлыми хвостами (например, Коши) использование стандартного отклонения может приводить к чрезмерному сглаживанию из-за влияния выбросов. В таких случаях применяют робастную оценку разброса, заменяя $\hat{\sigma}$ на

$$\hat{\sigma}_{\text{rob}} = \min \left(s, \frac{IQR}{1.34} \right).$$

Коэффициент 1.34 возникает из соотношения между стандартным отклонением и IQR для нормального распределения: $IQR \approx 1.34 \sigma$. Эта оценка менее чувствительна к выбросам. Кроме того, в робастной версии дополнительно используется множитель 0.9:

$$h_{\text{rob}} = 0.9 \cdot \min \left(s, \frac{IQR}{1.34} \right) \cdot n^{-1/5}.$$

Коэффициент 0.9 был выбран эмпирически как компромиссное значение, обеспечивающее баланс между робастностью и эффективностью. Меньший коэффициент (например, 0.8) сделал бы окно более узким, что улучшило бы выявление пиков в распределениях, отличных от нормального, но привело бы к большей потере эффективности (увеличению среднеквадратичной ошибки) для нормального распределения. С другой стороны, использование 1.0 (или исходного 1.06) дало бы хорошие результаты для нормального закона, но ухудшило бы поведение на распределениях с тяжёлыми хвостами. Значение 0.9 гарантирует, что для нормального распределения потеря эффективности не превышает 10%, что считается приемлемой платой за универсальность метода. В работе эта модификация применяется для распределения Коши.

Исследуемые распределения

1. Нормальное распределение $N(0, 1)$:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad F(x) = \Phi(x).$$

2. Распределение Коши $C(0, 1)$:

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad F(x) = \frac{1}{\pi} \arctan x + \frac{1}{2}.$$

3. Распределение Лапласа $L(0, 1/\sqrt{2})$:

$$f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}, \quad F(x) = \begin{cases} \frac{1}{2} e^{\sqrt{2}x}, & x \leq 0, \\ 1 - \frac{1}{2} e^{-\sqrt{2}x}, & x > 0. \end{cases}$$

4. Распределение Пуассона $P(5)$:

$$P(X = k) = \frac{5^k e^{-5}}{k!}, \quad k = 0, 1, 2, \dots, \quad F(x) = \sum_{k \leq x} \frac{5^k e^{-5}}{k!}.$$

5. Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$:

$$f(x) = \frac{1}{2\sqrt{3}}, \quad |x| \leq \sqrt{3}, \quad F(x) = \frac{x + \sqrt{3}}{2\sqrt{3}}, \quad x \in [-\sqrt{3}, \sqrt{3}].$$

3 Реализация

Язык программирования: Python 3.13

Среда разработки: VS Code

Библиотеки:

- `numpy` – генерация выборок и вычисления;
- `scipy.stats` – теоретические функции распределения и плотности;
- `matplotlib.pyplot` – построение графиков.

Алгоритм программы:

1. Для каждого распределения и каждого объёма выборки $n = 20, 60, 100$ генерируется одна реализация случайной выборки.
2. Для каждого n строятся два графика: график плотности (гистограмма, ядерная оценка, теоретическая плотность) и график функции распределения (ЭФР, теоретическая ФР, ЭФР из гистограммы). Все шесть подграфиков для трёх объёмов размещаются на одном рисунке.
3. Параметры гистограммы выбираются следующим образом:
 - Для Коши – вручную: в зависимости от n задаются интервал и число бинов (как в лабораторной работе №1);
 - Для Пуассона – бины шириной 1, центрированные по целым числам;
 - Для остальных непрерывных распределений – адаптивное правило Фридмана–Дьякониса (`bins='fd'`) с диапазоном, указанным в условии.
4. Ядерная оценка строится с помощью собственной функции `gaussian_kde`, реализующей гауссово ядро. Ширина окна h_{KDE} выбирается методом Сильвермана (обычным или робастным для Коши).
5. ЭФР из гистограммы вычисляется как кумулятивная сумма нормированных частот.
6. Дополнительно для равномерного и лапласовского распределений ($n = 100$) строятся графики, демонстрирующие влияние ширины окна h_{KDE} на KDE (при $h_{\text{KDE}} = 0.5h_s, h_s, 2h_s$).

Все графики сохраняются в папку `images/`.

4 Результаты

На рисунках 1–5 представлены графики для каждого распределения: верхний ряд – плотности (гистограмма, ядерная оценка, теоретическая плотность), нижний ряд – функции распределения (ЭФР, теоретическая ФР, ЭФР из гистограммы). На рис. 6 и 7 показано влияние ширины окна h_{KDE} на ядерную оценку для равномерного и лапласовского распределений.




Рис. 1: Нормальное распределение: графики плотности и функции распределения.

Распределение Коши




Рис. 2: Распределение Коши: графики плотности и функции распределения.

Распределение Лапласа




Рис. 3: Распределение Лапласа: графики плотности и функции распределения.

Распределение Пуассона




Рис. 4: Распределение Пуассона ($\lambda = 5$): графики плотности (здесь под плотностью понимается дискретная вероятность) и функции распределения.

Распределение Равномерное




Рис. 5: Равномерное распределение: графики плотности и функции распределения.




Рис. 6: Влияние ширины окна h_{KDE} на ядерную оценку (равномерное, $n = 100$).




Рис. 7: Влияние ширины окна h_{KDE} на ядерную оценку (Лапласа, $n = 100$).

5 Обсуждение

Сходимость эмпирической функции распределения

Из представленных графиков (рис. 1–5) видно, что с ростом объёма выборки эмпирическая функция распределения всё точнее приближает теоретическую. При $n = 20$ ступенчатая линия ещё заметно отклоняется от гладкой кривой. При $n = 60$ отклонения уменьшаются, а при $n = 100$ эмпирическая и теоретическая функции практически совпадают для всех распределений, включая Коши. Это наглядно демонстрирует теорему Гливенко–Кантелли.

Для дискретного распределения Пуассона эмпирическая функция также хорошо приближает теоретическую, хотя из-за ступенчатой природы обеих функций визуально большая разница заметна лишь при малых n . ЭФР, полученная из гистограммы (оранжевая пунктирная линия), хорошо согласуется с обычной ЭФР, что подтверждает корректность выбора бинов.

Ядерные оценки плотности

Ядерная оценка плотности даёт гладкую кривую, которая при увеличении n приближается к теоретической плотности. Для нормального распределения уже при $n = 20$ оценка довольно близка к истинной кривой, а при $n = 100$ практически неотличима. Для распределения Лапласа также при увеличении n ядерная оценка приближается к теоретической плотности.

Для распределения Коши, ввиду его тяжёлых хвостов, выбран интервал $[-20, 20]$, позволяющий увидеть основную форму плотности. При малых n ядерная оценка может иметь ложные пики из-за редких выбросов, однако с ростом объёма выборки форма приближается к теоретической; использование робастной оценки ширины окна улучшает качество приближения.

Для равномерного распределения ядерная оценка «размазывает» плотность за пределы интервала $[-\sqrt{3}, \sqrt{3}]$, что является следствием граничного эффекта. При увеличении n этот эффект ослабевает, но полностью не исчезает — ядерное сглаживание всегда даёт ненулевые значения вне носителя, если не использовать специальные граничные поправки.

Для распределения Пуассона ядерная оценка (применённая к дискретным данным) даёт непрерывную кривую, которая при $n = 100$ хорошо огибает теоретические вероятности, хотя, строго говоря, для дискретных данных более адекватной оценкой остаётся гистограмма с шириной бина 1.

Влияние ширины окна h_{KDE}

На рис. 6 и 7 показано, как выбор параметра h_{KDE} влияет на ядерную оценку. При $h_{\text{KDE}} = 0.5h_s$ (пунктир) кривая более детальна, но может быть зашумлена; при $h_{\text{KDE}} = 2h_s$ (точки) – сильно сглажена, теряются детали. Оптимальное значение h_s (сплошная линия) даёт наилучшее визуальное соответствие теоретической плотности. Это демонстрирует компромисс между смещением и дисперсией в ядерном оценивании.

Сравнение с гистограммой

На графиках плотности гистограмма показана серым полупрозрачным фоном. Гистограмма является ступенчатой и сильно зависит от числа интервалов, тогда как ядерная оценка гладкая и более устойчива. При малых выборках гистограмма может давать неинформативные пустые бины, в то время как ядерная оценка «заполняет» промежутки, что не всегда желательно (например, для дискретных данных). Тем не менее, при больших n гистограмма также хорошо приближает плотность.

6 Выводы

В ходе выполнения лабораторной работы были решены все поставленные задачи:

1. Сгенерированы выборки трёх объёмов ($n = 20, 60, 100$) для пяти распределений: нормального, Коши, Лапласа, Пуассона и равномерного.
2. Для каждой выборки построены графики эмпирической функции распределения (совместно с теоретической и ЭФР из гистограммы) и ядерной оценки плотности (совместно с гистограммой и теоретической плотностью).
3. Визуальный анализ графиков подтвердил теоретические результаты:
 - Эмпирическая функция распределения равномерно сходится к теоретической с ростом n (теорема Гливенко–Кантелли).
 - Ядерная оценка плотности при увеличении объёма выборки приближается к истинной плотности, но чувствительна к граничным эффектам и тяжёлым хвостам. Использование робастной оценки ширины окна улучшает поведение для распределения Коши.
 - Для равномерного распределения наблюдается характерный «выброс» ядерной оценки за границы носителя, что связано с отсутствием граничных поправок.
4. Сравнение с гистограммой показало преимущества ядерного сглаживания в получении гладких оценок, но также и его ограничения.
5. Дополнительные эксперименты с варьированием ширины окна h_{KDE} наглядно продемонстрировали компромисс между смещением и дисперсией в ядерном оценивании.

Таким образом, эмпирическая функция распределения и ядерная оценка плотности являются состоятельными и удобными инструментами непараметрического оценивания, применимыми к данным из различных распределений.

7 Список литературы

1. Кобзарь А.И. "Прикладная математическая статистика."— М.: Физматлит, 2006.
2. Скотт Д.У. "Многомерное оценивание плотности: теория, практика и визуализация."— Wiley, 2015.
3. Документация библиотек NumPy, SciPy, Matplotlib: <https://docs.scipy.org/doc/>, <https://matplotlib.org/stable/contents.html>

8 Приложение

Ссылка на репозиторий с исходным кодом: <https://github.com/zhitkovns/matstat/tree/lab4>