

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Направление подготовки
"01.03.02. Прикладная математика и информатика"

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №5
"Корреляционный анализ и эллипсы рассеивания"

Работу
выполнил:
Житков Н. С.
Группа:
5030102/30201

Санкт-Петербург
2026

Содержание

1	Постановка задачи	3
2	Теоретическая часть	3
3	Реализация	4
4	Результаты	5
5	Обсуждение	7
6	Выводы	8
7	Список литературы	9
8	Приложение	9

1 Постановка задачи

Цель работы: изучить методы корреляционного анализа, научиться вычислять и интерпретировать коэффициенты корреляции, а также освоить визуализацию ковариационной структуры двумерных данных с помощью эллипсов рассеивания.

Задачи:

- Сгенерировать двумерные выборки объёмом $n = 20, 60, 100$ из:
 1. Двумерного нормального распределения $N(0, 0, 1, 1, \rho)$ с $\rho = 0, 0.5, 0.9$;
 2. Смеси $0.9 N(0, 0, 1, 1, 0.9) + 0.1 N(0, 0, 10, 10, -0.9)$.
- Для каждой выборки вычислить три коэффициента корреляции: Пирсона, Спирмена и квадрантный. Повторить эксперимент 1000 раз, найти среднее и дисперсию каждого коэффициента.
- Построить диаграммы рассеивания и эллипсы равновероятности для одной реализации из каждого сценария.
- Сравнить полученные оценки с истинным значением коэффициента корреляции (где оно известно) и проанализировать влияние объёма выборки и формы распределения.

2 Теоретическая часть

Коэффициент корреляции Пирсона

Для двумерной выборки (x_i, y_i) , $i = 1, \dots, n$ выборочный коэффициент корреляции Пирсона определяется как

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}.$$

Он измеряет силу линейной связи между переменными, принимая значения от -1 до 1 . $r = 1$ соответствует полной положительной линейной зависимости, $r = -1$ — полной отрицательной, $r = 0$ — отсутствию линейной корреляции (но не обязательно независимости).

Коэффициент корреляции Спирмена

Коэффициент Спирмена является ранговой мерой связи. Для каждой переменной значения заменяются их рангами: упорядочиваем все наблюдения по возрастанию, присваиваем наименьшему значению ранг 1, следующему — ранг 2 и т.д. При наличии совпадающих значений (связей) каждому из них присваивается средний ранг (среднее арифметическое тех рангов, которые они заняли бы, если бы были различны). Обозначим полученные ранги $R(x_i)$ и $R(y_i)$. Тогда коэффициент Спирмена вычисляется как обычный коэффициент Пирсона по рангам:

$$\rho_S = \frac{\sum_{i=1}^n (R(x_i) - \bar{R}_x)(R(y_i) - \bar{R}_y)}{\sqrt{\sum_{i=1}^n (R(x_i) - \bar{R}_x)^2 \sum_{i=1}^n (R(y_i) - \bar{R}_y)^2}}.$$

Спирмен улавливает любую монотонную (не обязательно линейную) зависимость и устойчив к выбросам, так как использует только порядок значений, а не их абсолютную величину.

Квадрантный коэффициент

Квадрантный (знаковый) коэффициент корреляции основан на медианах. Обозначим $\tilde{x} = \text{med}(x_i)$, $\tilde{y} = \text{med}(y_i)$. Тогда

$$r_q = \frac{1}{n} \sum_{i=1}^n \text{sign}((x_i - \tilde{x})(y_i - \tilde{y})).$$

Он показывает, в каком квадранте относительно медиан лежит большинство точек. Его значения также лежат в $[-1, 1]$. Квадрантный коэффициент является робастной мерой связи, но менее чувствительной, чем Пирсон или Спирмен.

Эллипс равновероятности

Для двумерного нормального распределения множество точек с постоянной плотностью вероятности представляет собой эллипс, описываемый уравнением

$$(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = \chi_2^2(p),$$

где $\chi_2^2(p)$ – квантиль χ^2 -распределения с 2 степенями свободы для вероятности p (например, $p = 0.5$ даёт эллипс, содержащий 50% вероятности). Квантиль уровня p – это такое число q , что вероятность того, что случайная величина χ^2 (распределённая по закону хи-квадрат с 2 степенями свободы) не превышает q , равна p :

$$P(\chi^2 \leq q) = p.$$

Чем больше p , тем больше квантиль и тем шире эллипс. На практике параметры $\boldsymbol{\mu}$ и $\boldsymbol{\Sigma}$ заменяют выборочными средними и ковариационной матрицей. Для визуализации используют эллипс, ориентированный по собственным векторам ковариационной матрицы, с полуосями, пропорциональными квадратным корням из собственных значений.

Исследуемые распределения

1. Двумерное нормальное $N(0, 0, 1, 1, \rho)$ с плотностью:

$$f(x, y) = \frac{1}{2\pi\sqrt{1-\rho^2}} \exp\left(-\frac{x^2 - 2\rho xy + y^2}{2(1-\rho^2)}\right).$$

Здесь $MX = MY = 0$, $DX = DY = 1$, $\text{Cov}(X, Y) = \rho$.

2. Смесь двух нормальных распределений:

$$0.9 N(0, 0, 1, 1, 0.9) + 0.1 N(0, 0, 10, 10, -0.9).$$

Первая компонента описывает основную массу данных с сильной положительной корреляцией, вторая – редкие выбросы с большой дисперсией и сильной отрицательной корреляцией.

3 Реализация

Язык программирования: Python 3.13

Среда разработки: VS Code

Библиотеки:

- `numpy` – генерация выборок и вычисления;
- `scipy.stats` – расчёт ранговой корреляции, многомерное нормальное;
- `matplotlib.pyplot` – построение диаграмм рассеяния и эллипсов.

Алгоритм программы:

1. Для каждого сценария (4 варианта: три нормальных с разным ρ и смесь) и каждого объёма выборки $n = 20, 60, 100$:
 - Генерируется 1000 независимых двумерных выборок.
 - Для каждой выборки вычисляются три коэффициента корреляции.
 - Находятся средние значения и дисперсии (с `ddof=0` - для вычисления генеральной дисперсии) для каждого коэффициента.
 - Сохраняется одна (последняя) выборка для визуализации.
2. Для каждой сохранённой выборки строится диаграмма рассеяния и эллипс рассеивания (на уровне 50%). Уровень 50% выбран как компромисс между информативностью и наглядностью: такой эллипс достаточно компактен, чтобы отразить основные направления разброса, но не слишком мал, чтобы терять детали. Эллипс строится по выборочным средним и ковариационной матрице.
3. Результаты записываются в CSV-файл для последующего включения в отчёт.

4 Результаты

В таблицах 1-2 представлены средние значения и дисперсии коэффициентов корреляции, полученные в 1000 повторениях. На рисунках 1–4 показаны диаграммы рассеяния и эллипсы рассеивания для каждого сценария.

Пояснение к диаграммам: у коэффициентов корреляции указывается два числа через " $\pm$ ". Первое число — это среднее значение коэффициента корреляции по 1000 повторениям, а второе — стандартное отклонение (корень из дисперсии) этих 1000 значений. Это мера разброса оценки, показывающая, насколько коэффициент может меняться от выборки к выборке. Чем меньше второе число, тем устойчивее оценка.

Результаты для нормального распределения

ρ	n	Пирсон		Спирмен		Квадрантный	
		E	D	E	D	E	D
0	20	0.0060	0.0531	0.0049	0.0520	0.0004	0.0515
	60	0.0019	0.0173	0.0008	0.0175	0.0009	0.0167
	100	0.0008	0.0100	0.0000	0.0101	0.0023	0.0104
0.5	20	0.4864	0.0310	0.4589	0.0349	0.3238	0.0478
	60	0.4937	0.0101	0.4710	0.0110	0.3297	0.0152
	100	0.4953	0.0059	0.4753	0.0066	0.3320	0.0091
0.9	20	0.8966	0.0021	0.8674	0.0045	0.6968	0.0289
	60	0.8992	0.0006	0.8835	0.0011	0.7103	0.0088
	100	0.8994	0.0004	0.8868	0.0006	0.7122	0.0051

Таблица 1: Средние и дисперсии коэффициентов корреляции для двумерного нормального распределения




Рис. 1: Диаграммы рассеяния и эллипсы для нормального распределения с $\rho = 0$




Рис. 2: Диаграммы рассеяния и эллипсы для нормального распределения с $\rho = 0.5$




Рис. 3: Диаграммы рассеяния и эллипсы для нормального распределения с $\rho = 0.9$

Результаты для смеси распределений

n	Пирсон		Спирмен		Квадрантный	
	E	D	E	D	E	D
20	0.1703	0.2695	0.5209	0.0597	0.5246	0.0380
60	0.0601	0.1182	0.5336	0.0229	0.5508	0.0119
100	0.0177	0.0755	0.5390	0.0141	0.5644	0.0068

Таблица 2: Средние и дисперсии коэффициентов корреляции для смеси




Рис. 4: Диаграммы рассеяния и эллипсы для смеси

5 Обсуждение

Нормальное распределение

Из таблицы 1 видно, что для всех значений ρ выборочный коэффициент Пирсона является практически несмещённой оценкой: его среднее значение уже при $n = 20$ очень близко к теоретическому ρ , а с ростом n дисперсия убывает примерно как $1/n$ (например, для $\rho = 0.5$ дисперсия уменьшается от 0.031 при $n = 20$ до 0.0059 при $n = 100$). Это согласуется с классическими результатами математической статистики.

Коэффициент Спирмена систематически немного занижен по сравнению с Пирсоном. При $\rho = 0.5$ его среднее значение при $n = 100$ составляет 0.475 против 0.495 у Пирсона; при $\rho = 0.9$: 0.887 против 0.899. Такое «сжатие» к нулю характерно для ранговых мер даже при линейной зависимости, поскольку они используют только порядок наблюдений, а не их абсолютные величины.

Квадрантный коэффициент оказывается ещё более смещённым: при $\rho = 0.5$ он даёт около 0.332, при $\rho = 0.9$: около 0.712. Это объясняется его конструкцией: он учитывает лишь знак отклонения от медиан, поэтому при сильной корреляции часть точек, расположенных в «неправильных» квадрантах (например, на краях распределения), снижает оценку. Дисперсия квадрантного коэффициента также выше, чем у двух других мер, что свидетельствует о его большей изменчивости.

Для $\rho = 0$ все три коэффициента в среднем близки к нулю, а их дисперсии убывают с ростом n , что подтверждает состоятельность.

Смесь распределений

Для смеси $0.9 N(0, 0, 1, 1, 0.9) + 0.1 N(0, 0, 10, 10, -0.9)$ наблюдается принципиально иная картина (таблица 2).

Коэффициент Пирсона сильно зависит от объёма выборки: при $n = 20$ его среднее значение примерно равно 0.170, при $n = 60$ – 0.060, при $n = 100$ – всего 0.018. Это объясняется тем, что редкие выбросы из второй компоненты имеют большую дисперсию и отрицательную корреляцию. При малых n они могут сильно исказить оценку, а с ростом объёма данных их влияние усредняется, и Пирсон стремится к нулю. Дисперсия Пирсона также очень велика при малых n (0.2695), что отражает высокую чувствительность к наличию выбросов.

В отличие от Пирсона, коэффициенты Спирмена и квадрантный демонстрируют устойчивость: их средние значения остаются практически постоянными при изменении n и составляют около 0.54 и 0.56 соответственно. Это объясняется тем, что основная масса данных (90% из первой компоненты) имеет сильную положительную корреляцию ($\rho = 0.9$), и ранговые методы, игнорируя абсолютные величины, успешно выделяют эту структуру. Дисперсии этих

коэффициентов заметно меньше, чем у Пирсона, что подтверждает их робастность.

Визуализация: диаграммы рассеяния и эллипсы

Диаграммы рассеяния (рис. 1–4) наглядно иллюстрируют полученные числовые результаты. Для нормального распределения эллипсы рассеивания хорошо соответствуют форме облака точек: при $\rho = 0$ эллипсы ориентированы по осям (практически окружности), при $\rho = 0.5$ – наклонены, при $\rho = 0.9$ – сильно вытянуты вдоль линии регрессии.

Для смеси наблюдается чёткое разделение на две группы: основная масса точек (90%) образует плотное облако с положительной корреляцией, а редкие выбросы (10%) разбросаны с отрицательной корреляцией и большим разбросом. Эллипс, построенный по выборочным средним и ковариации, при малых n сильно искажён из-за выбросов, но с ростом объёма данных его форма стабилизируется и начинает отражать в основном структуру основной компоненты.

6 Выводы

В ходе выполнения лабораторной работы были решены все поставленные задачи:

1. Сгенерированы двумерные выборки разного объёма ($n = 20, 60, 100$) из нормального распределения с $\rho = 0, 0.5, 0.9$ и из смеси двух нормальных законов.
2. Для каждого сценария вычислены средние и дисперсии коэффициентов корреляции Пирсона, Спирмена и квадрантного (измерения проводились 1000 раз).
3. Построены диаграммы рассеяния и эллипсы равновероятности (уровень 50%), иллюстрирующие ковариационную структуру.
4. Анализ результатов позволил сделать следующие выводы:
 - Для нормального распределения коэффициент Пирсона является несмещённой и эффективной оценкой; Спирмен и квадрантный дают систематически заниженные значения, особенно при сильной корреляции, но их дисперсия также убывает с ростом n .
 - Для смеси распределений Пирсон сильно чувствителен к выбросам: при малых выборках его оценка может быть существенно искажена, а с увеличением n стремится к нулю. Ранговые коэффициенты (Спирмен, квадрантный) остаются устойчивыми и оценивают корреляцию основной компоненты (около 0.55).
 - Диаграммы рассеяния с эллипсами подтверждают численные выводы: для нормальных данных форма облака и эллипса хорошо согласуются с истинным ρ ; для смеси визуализация позволяет увидеть структуру с выбросами.

Таким образом, выбор коэффициента корреляции должен зависеть от предполагаемого характера данных: для нормальных выборок без выбросов предпочтителен коэффициент Пирсона; при наличии аномальных наблюдений или нелинейных связей более надёжными являются ранговые меры (Спирмен) или знаковые (квадрантный). Эллипсы рассеивания служат полезным инструментом для визуальной диагностики формы и степени корреляции.

7 Список литературы

1. Кобзарь А.И. "Прикладная математическая статистика."— М.: Физматлит, 2006.
2. Андерсон Т. "Введение в многомерный статистический анализ."— М.: Физматлит, 1963.
3. Документация библиотек NumPy, SciPy, Matplotlib: <https://docs.scipy.org/doc/>, <https://matplotlib.org/stable/contents.html>

8 Приложение

Ссылка на репозиторий с исходным кодом: <https://github.com/zhitkovns/matstat/tree/lab5>