

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Направление подготовки
"01.03.02. Прикладная математика и информатика"

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №5
"Корреляционный анализ и эллипсы рассеивания"

Работу
выполнил:
Житков Н. С.
Группа:
5030102/30201

Санкт-Петербург
2026

Содержание

1	Постановка задачи	3
2	Теоретическая часть	3
3	Реализация	5
4	Результаты	6
5	Обсуждение	8
6	Выводы	8
7	Список литературы	9
8	Приложение	9

1 Постановка задачи

Цель работы: изучить методы корреляционного анализа, научиться вычислять и интерпретировать коэффициенты корреляции, а также освоить визуализацию ковариационной структуры двумерных данных с помощью эллипсов рассеивания.

Задачи:

- Сгенерировать двумерные выборки объёмом $n = 20, 60, 100$ из:
 1. Двумерного нормального распределения $N(0, 0, 1, 1, \rho)$ с $\rho = 0, 0.5, 0.9$;
 2. Смеси $0.9 N(0, 0, 1, 1, 0.9) + 0.1 N(0, 0, 10, 10, -0.9)$.
- Для каждой выборки вычислить три коэффициента корреляции: Пирсона, Спирмена и квадрантный. Повторить эксперимент 1000 раз, найти среднее и дисперсию каждого коэффициента.
- Построить диаграммы рассеяния и эллипсы равновероятности для одной реализации из каждого сценария.
- Сравнить полученные оценки с истинным значением коэффициента корреляции (где оно известно) и проанализировать влияние объёма выборки и формы распределения.

2 Теоретическая часть

Двумерное нормальное распределение

Двумерная случайная величина (X, Y) называется распределённой нормально, если её плотность вероятности определена формулой

$$N(x, y, \bar{x}, \bar{y}, \sigma_x, \sigma_y, \rho) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x-\bar{x})^2}{\sigma_x^2} - 2\rho \frac{(x-\bar{x})(y-\bar{y})}{\sigma_x\sigma_y} + \frac{(y-\bar{y})^2}{\sigma_y^2} \right] \right\},$$

где $\bar{x}, \bar{y}$ – математические ожидания, σ_x, σ_y – средние квадратические отклонения, ρ – коэффициент корреляции.

Коэффициент корреляции Пирсона

Для двумерной выборки (x_i, y_i) , $i = 1, \dots, n$ выборочный коэффициент корреляции Пирсона определяется как

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}.$$

Он измеряет силу линейной связи между переменными, принимая значения от -1 до 1 . $r = 1$ соответствует полной положительной линейной зависимости, $r = -1$ – полной отрицательной, $r = 0$ – отсутствию линейной корреляции (но не обязательно независимости).

Коэффициент корреляции Спирмена

Коэффициент Спирмена является ранговой мерой связи. Для его вычисления значения каждой переменной заменяются их рангами. Ранги получают следующим образом: все наблюдения упорядочивают по возрастанию, наименьшему присваивают ранг 1, следующему – ранг 2 и

т.д. Если несколько значений совпадают, им присваивается средний ранг (среднее арифметическое рангов, которые они заняли бы, если бы были различны). Обозначим ранги $R(x_i)$ и $R(y_i)$. Тогда коэффициент Спирмена вычисляется как обычный коэффициент Пирсона по рангам:

$$\rho_S = \frac{\sum_{i=1}^n (R(x_i) - \bar{R}_x)(R(y_i) - \bar{R}_y)}{\sqrt{\sum_{i=1}^n (R(x_i) - \bar{R}_x)^2 \sum_{i=1}^n (R(y_i) - \bar{R}_y)^2}},$$

где $\bar{R}_x = \bar{R}_y = (n+1)/2$ – среднее значение рангов. Спирмен улавливает любую монотонную (не обязательно линейную) зависимость и устойчив к выбросам, так как использует только порядок значений.

Квадрантный коэффициент корреляции

Выборочный квадратный коэффициент корреляции определяется через количества точек, попавших в четыре квадранта относительно точки с координатами $(\text{med } x, \text{med } y)$:

$$r_Q = \frac{(n_1 + n_3) - (n_2 + n_4)}{n},$$

где

- n_1 – количество точек с $x > \text{med } x, y > \text{med } y$;
- n_2 – количество точек с $x < \text{med } x, y > \text{med } y$;
- n_3 – количество точек с $x < \text{med } x, y < \text{med } y$;
- n_4 – количество точек с $x > \text{med } x, y < \text{med } y$.

Эта мера робастна к выбросам, так как зависит только от знаков отклонений от медиан, а не от абсолютных величин. Эквивалентная формула:

$$r_Q = \frac{1}{n} \sum_{i=1}^n \text{sgn}((x_i - \text{med } x)(y_i - \text{med } y)).$$

Эллипсы рассеивания

Для двумерного нормального распределения сечения поверхности плотности вероятности плоскостями, параллельными плоскости xOy , дают эллипсы. Уравнение проекции такого эллипса на плоскость xOy имеет вид:

$$\frac{(x - \bar{x})^2}{\sigma_x^2} - 2\rho \frac{(x - \bar{x})(y - \bar{y})}{\sigma_x \sigma_y} + \frac{(y - \bar{y})^2}{\sigma_y^2} = \text{const.}$$

Центр эллипса находится в точке $(\bar{x}, \bar{y})$. Ориентация осей определяется углом α , удовлетворяющим

$$\text{tg } 2\alpha = \frac{2\rho\sigma_x\sigma_y}{\sigma_x^2 - \sigma_y^2}.$$

Любой эллипс рассеивания для двумерного нормального распределения однозначно задаётся пятью параметрами:

1. координаты центра эллипса (математические ожидания) $(\bar{x}, \bar{y})$ – 2 параметра;
2. средние квадратические отклонения σ_x и σ_y – 2 параметра;

3. коэффициент корреляции ρ – 1 параметр (он определяет ориентацию и вытянутость эллипса).

Для теоретического эллипса рассеивания, содержащего долю вероятности p (например, $p = 0.5$), константа в правой части равна $\chi_2^2(p)$ – квантилю χ^2 -распределения с 2 степенями свободы. На практике неизвестные параметры $\bar{x}, \bar{y}, \sigma_x, \sigma_y, \rho$ заменяются их выборочными оценками:

$$\hat{x} = \frac{1}{n} \sum x_i, \quad \hat{y} = \frac{1}{n} \sum y_i, \quad \hat{\sigma}_x^2 = \frac{1}{n-1} \sum (x_i - \hat{x})^2, \quad \hat{\sigma}_y^2 = \frac{1}{n-1} \sum (y_i - \hat{y})^2, \quad \hat{\rho} = r$$

Эллипс, построенный по этим оценкам, называют выборочным эллипсом рассеивания. Для его построения удобно использовать собственные значения и векторы выборочной ковариационной матрицы: полуоси равны $\sqrt{\chi_2^2(p)\lambda_1}$ и $\sqrt{\chi_2^2(p)\lambda_2}$, ориентация определяется первым собственным вектором.

Моделирование смеси распределений

Смесь $0.9 N(0, 0, 1, 1, 0.9) + 0.1 N(0, 0, 10, 10, -0.9)$ генерируется в программе следующим образом:

1. Генерируется выборка $\mathbf{X}_1$ объёма n из первого двумерного нормального распределения с параметрами $\bar{x} = \bar{y} = 0, \sigma_x = \sigma_y = 1, \rho = 0.9$. Ковариационная матрица имеет вид $\Sigma_1 = \begin{pmatrix} 1 & 0.9 \\ 0.9 & 1 \end{pmatrix}$.
2. Генерируется выборка $\mathbf{X}_2$ объёма n из второго двумерного нормального распределения с параметрами $\bar{x} = \bar{y} = 0, \sigma_x = \sigma_y = \sqrt{10}, \rho = -0.9$. Ковариационная матрица: $\Sigma_2 = \begin{pmatrix} 10 & -9 \\ -9 & 10 \end{pmatrix}$, поскольку $\text{cov}(X, Y) = \rho\sigma_x\sigma_y = -0.9 \cdot \sqrt{10}\sqrt{10} = -9$.
3. Для каждого наблюдения $i = 1, \dots, n$ независимо выбирается номер компоненты: с вероятностью 0.9 выбирается первая компонента, с вероятностью 0.1 – вторая. Это реализуется с помощью биномиального индикатора $m_i \sim \text{Bernoulli}(0.1)$ (случайная величина (вектор) из n независимых значений, каждое из которых равно 0 с вероятностью 0.9 и 1 с вероятностью 0.1).
4. Результирующая выборка формируется как $(x_i, y_i) = \begin{cases} (\mathbf{X}_1)_i, & m_i = 0, \\ (\mathbf{X}_2)_i, & m_i = 1. \end{cases}$

Такая процедура позволяет получить выборку, в которой 90% точек принадлежат компактному облаку с сильной положительной корреляцией, а остальные 10% – редкие выбросы с большой дисперсией и сильной отрицательной корреляцией.

3 Реализация

Язык программирования: Python 3.13

Среда разработки: VS Code

Библиотеки:

- `numpy` – генерация выборок и вычисления;
- `scipy.stats` – расчёт ранговой корреляции;

- `matplotlib.pyplot` – построение диаграмм рассеяния и эллипсов.

Алгоритм программы:

1. Для каждого сценария (4 варианта) и каждого объёма выборки $n = 20, 60, 100$:
 - Генерируется 1000 независимых двумерных выборок.
 - Для каждой выборки вычисляются три коэффициента корреляции.
 - Находятся средние значения и дисперсии (с `ddof=0`, генеральная дисперсия).
 - Сохраняется одна (последняя) выборка для визуализации.
2. Для каждой сохранённой выборки строится диаграмма рассеяния и эллипс рассеивания на уровне 50%. Для корректного отображения формы эллипса устанавливается равный масштаб осей (`set_aspect('equal')`) и фиксируются пределы по осям.
3. Результаты записываются в CSV-файл.

4 Результаты

В таблицах 1 и 2 представлены средние значения и дисперсии коэффициентов корреляции, полученные в 1000 повторениях. На рисунках 1–4 показаны диаграммы рассеяния и эллипсы рассеивания для каждого сценария.

Результаты для нормального распределения

ρ	n	Пирсон		Спирмен		Квадрантный	
		E	D	E	D	E	D
3^*0	20	0.0060	0.0531	0.0049	0.0520	0.0004	0.0515
	60	0.0019	0.0173	0.0008	0.0175	0.0009	0.0167
	100	-0.0008	0.0100	-0.0000	0.0101	-0.0023	0.0104
$3^*0.5$	20	0.4864	0.0310	0.4589	0.0349	0.3238	0.0478
	60	0.4937	0.0101	0.4710	0.0110	0.3297	0.0152
	100	0.4953	0.0059	0.4753	0.0066	0.3320	0.0091
$3^*0.9$	20	0.8966	0.0021	0.8674	0.0045	0.6968	0.0289
	60	0.8992	0.0006	0.8835	0.0011	0.7103	0.0088
	100	0.8994	0.0004	0.8868	0.0006	0.7122	0.0051

Таблица 1: Средние и дисперсии коэффициентов корреляции для двумерного нормального распределения




Рис. 1: Диаграммы рассеяния и эллипсы для нормального распределения с $\rho = 0$




Рис. 2: Диаграммы рассеяния и эллипсы для нормального распределения с $\rho = 0.5$




Рис. 3: Диаграммы рассеяния и эллипсы для нормального распределения с $\rho = 0.9$

Результаты для смеси распределений

n	Пирсон		Спирмен		Квадрантный	
	E	D	E	D	E	D
20	0.1703	0.2695	0.5209	0.0597	0.5246	0.0380
60	0.0601	0.1182	0.5336	0.0229	0.5508	0.0119
100	0.0177	0.0755	0.5390	0.0141	0.5644	0.0068

Таблица 2: Средние и дисперсии коэффициентов корреляции для смеси




Рис. 4: Диаграммы рассеяния и эллипсы для смеси

5 Обсуждение

Нормальное распределение

Для нормального распределения коэффициент Пирсона является несмещённой оценкой ρ : средние значения близки к истинным, а дисперсии убывают как $1/n$. Коэффициент Спирмена систематически занижен (эффект сжатия к нулю), что связано с ранговым преобразованием. Квадрантный коэффициент даёт ещё более смещённые значения, особенно при $\rho = 0.9$ (около 0.71 против 0.9), поскольку он учитывает только знаки отклонений и теряет информацию о величине. Дисперсия квадрантного коэффициента выше, чем у Пирсона и Спирмена.

На рисунках 3 видно, что при $\rho = 0.9$ эллипс рассеивания с ростом n становится всё более вытянутым: при $n = 20$ форма ещё близка к окружности (из-за случайных колебаний выборочной ковариации), а при $n = 100$ эллипс уже сильно вытянут вдоль главной диагонали, что соответствует сильной положительной корреляции.

Смесь распределений

Моделирование смеси позволяет получить выборки, в которых 90% точек образуют тесное облако с положительной корреляцией, а 10% – разбросанные выбросы с отрицательной корреляцией. Коэффициент Пирсона сильно зависит от объёма выборки: при $n = 20$ среднее 0.170, при $n = 100$ – 0.018. Это происходит потому, что выбросы сильно смещают оценку, а с ростом n их влияние усредняется, и Пирсон стремится к нулю. Напротив, ранговые коэффициенты (Спирмен, квадрантный) оказываются устойчивыми и оценивают корреляцию основной компоненты (около 0.54–0.56). Их дисперсии также существенно меньше.

Эллипсы для смеси на рис. 4 построены только по точкам, попадающим в область $[-3.5, 3.5]$ (основное облако), чтобы форма эллипса не искажалась выбросами. При $n = 100$ эллипс становится очень узким, демонстрируя высокую положительную корреляцию внутри первой компоненты.

Сравнение методов

В целом, для нормальных данных без выбросов предпочтителен коэффициент Пирсона – он несмещён и имеет наименьшую дисперсию. При наличии выбросов следует использовать ранговые меры (Спирмен) или квадрантную, которые устойчивы к аномальным наблюдениям. Эллипсы рассеивания с равным масштабом осей дают корректное визуальное представление о форме и ориентации облака точек.

6 Выводы

В ходе выполнения лабораторной работы:

1. Сгенерированы двумерные выборки из нормального распределения с $\rho = 0, 0.5, 0.9$ и из смеси двух нормальных распределений.
2. Вычислены средние и дисперсии коэффициентов Пирсона, Спирмена и квадрантного по 1000 повторений.
3. Построены диаграммы рассеяния и эллипсы рассеивания с равным масштабом осей.
4. Установлено:

- Для нормальных данных Пирсон несмещён и эффективен; Спирмен и квадрантный дают заниженные оценки.
- Для смеси Пирсон сильно чувствителен к выбросам, тогда как ранговые коэффициенты робастны.
- Эллипсы рассеивания наглядно демонстрируют ковариационную структуру; равный масштаб осей позволяет корректно оценить вытянутость.

Таким образом, выбор коэффициента корреляции должен зависеть от предполагаемого характера данных: для данных без выбросов предпочтителен коэффициент Пирсона; при наличии аномалий более надёжны ранговые меры (Спирмен) или квадрантную. Эллипсы рассеивания служат эффективным инструментом визуализации.

7 Список литературы

1. Кобзарь А.И. "Прикладная математическая статистика."— М.: Физматлит, 2006.
2. Бабахина С.А., Баженов А.Н. "Практикум по математической статистике: Учебное пособие."— СПб.: СПбПУ, 2026.
3. Документация библиотек NumPy, SciPy, Matplotlib: <https://docs.scipy.org/doc/>, <https://matplotlib.org/stable/contents.html>

8 Приложение

Ссылка на репозиторий с исходным кодом: <https://github.com/zhitkovns/matstat/tree/lab5>