

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Направление подготовки
"01.03.02. Прикладная математика и информатика"

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №6

"Линейная регрессия. Метод наименьших квадратов и наименьших модулей"

Работу
выполнил:
Житков Н. С.
Группа:
5030102/30201

Санкт-Петербург
2026

Содержание

1	Постановка задачи	3
2	Теоретическая часть	3
3	Реализация	5
4	Результаты	5
5	Обсуждение	6
6	Выводы	7
7	Список литературы	7
8	Приложение	7

1 Постановка задачи

Цель работы: сравнить устойчивость двух методов оценивания параметров линейной регрессии — метода наименьших квадратов (МНК) и метода наименьших модулей (МНМ) — при наличии выбросов.

Задачи:

- Сгенерировать x_i равномерно на отрезке $[-1.8; 2]$ с шагом 0.2 (20 точек).
- Сгенерировать $y_i = 2 + 2x_i + \varepsilon_i$, где $\varepsilon_i \sim N(0, 1)$.
- Оценить параметры модели $y = a + bx$ двумя методами: МНК и МНМ.
- Повторить пункты 1–3, добавив выбросы: $y_1 \leftarrow y_1 + 10$, $y_{20} \leftarrow y_{20} - 10$.
- Построить графики регрессионных прямых и исходных данных с одинаковыми границами по осям для наглядности.
- Вычислить абсолютные и относительные погрешности оценок параметров.
- Сравнить результаты и сделать выводы об устойчивости методов.

2 Теоретическая часть

Нормы L_1 и L_2

Для заданных параметров a, b предсказанные значения равны $\hat{y}_i = a + bx_i$, а остатки (отклонения наблюдаемых значений от предсказанных) определяются как

$$r_i = y_i - \hat{y}_i = y_i - (a + bx_i), \quad i = 1, \dots, n.$$

Вектор остатков $\mathbf{r} = (r_1, r_2, \dots, r_n)$. Его L_1 -норма (сумма абсолютных величин) и L_2 -норма (евклидова длина) вычисляются по формулам:

$$\begin{aligned} \|\mathbf{r}\|_1 &= \sum_{i=1}^n |r_i| = \sum_{i=1}^n |y_i - (a + bx_i)|, \\ \|\mathbf{r}\|_2 &= \sqrt{\sum_{i=1}^n r_i^2} = \sqrt{\sum_{i=1}^n (y_i - (a + bx_i))^2}. \end{aligned}$$

Квадрат L_2 -нормы $\|\mathbf{r}\|_2^2 = \sum r_i^2$ используется в методе наименьших квадратов. L_1 -норма $\|\mathbf{r}\|_1$ используется в методе наименьших модулей. Различие в определении норм приводит к разной чувствительности к выбросам: L_2 -норма сильно увеличивает вклад больших остатков (за счёт возведения в квадрат), тогда как L_1 -норма растёт линейно, что делает её более робастной.

Метод наименьших квадратов (МНК)

МНК минимизирует сумму квадратов остатков, т.е. квадрат L_2 -нормы:

$$S(a, b) = \sum_{i=1}^n (y_i - a - bx_i)^2 = \|\mathbf{y} - a - b\mathbf{x}\|_2^2 \rightarrow \min.$$

Для нахождения минимума приравняем частные производные к нулю:

$$\frac{\partial S}{\partial a} = -2 \sum (y_i - a - bx_i) = 0, \quad \frac{\partial S}{\partial b} = -2 \sum x_i (y_i - a - bx_i) = 0.$$

Получаем систему нормальных уравнений:

$$\sum y_i = na + b \sum x_i, \quad \sum x_i y_i = a \sum x_i + b \sum x_i^2.$$

Решение:

$$b = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \quad a = \bar{y} - b\bar{x}.$$

МНК оптимален при нормальном распределении ошибок, но чувствителен к выбросам из-за квадратичного роста целевой функции.

Метод наименьших модулей (МНМ) и L_1 -регрессия

МНМ минимизирует сумму абсолютных отклонений, т.е. L_1 -норму:

$$L(a, b) = \sum_{i=1}^n |y_i - a - bx_i| = \|\mathbf{y} - a - b\mathbf{x}\|_1 \rightarrow \min.$$

В отличие от L_2 -нормы, L_1 -норма не возводит ошибки в квадрат, поэтому крупные остатки не доминируют. Это делает МНМ робастным к выбросам.

Аналитического решения для МНМ не существует. Задача сводится к линейному программированию, так как целевая функция кусочно-линейна. На практике используют численные методы, например, симплекс-метод для L_1 -регрессии или прямой поиск.

Метод оптимизации Нелдера–Мида

Для численного решения задачи МНМ в работе используется метод Нелдера–Мида (симплексный метод). Это прямой метод безусловной оптимизации, не требующий вычисления градиентов. Он строит симплекс в пространстве параметров (a, b) (треугольник) и на каждом шаге деформирует его (отражение, растяжение, сжатие) для поиска минимума целевой функции. Метод устойчив для негладких функций, таких как сумма модулей, и хорошо работает при малой размерности. Реализация из `scipy.optimize.minimize` с методом 'Nelder-Mead' используется в данной работе.

Почему выбран метод Нелдера–Мида

Метод Нелдера–Мида (симплексный метод) выбран по следующим причинам:

- **Не требует вычисления градиентов.** Целевая функция $L(a, b) = \sum |y_i - a - bx_i|$ является кусочно-линейной и недифференцируемой в точках, где $y_i = a + bx_i$. Методы, основанные на градиенте, здесь неприменимы или требуют специальных модификаций (субградиент). Нелдер–Мид работает только со значениями функции.
- **Робастность к негладкости.** Прямые методы поиска, такие как симплексный, устойчивы к изломам целевой функции и хорошо работают в малой размерности (в нашем случае 2 параметра).
- **Простота реализации и доступность.** Метод реализован в библиотеке `scipy.optimize` и не требует настройки сложных параметров.

- **Достаточная точность.** Для целей лабораторной работы (сравнение устойчивости МНК и МНМ) метод даёт оценки параметров с приемлемой точностью.

Таким образом, метод Нелдера–Мида является удобным и эффективным выбором для решения задачи L_1 -регрессии.

Абсолютная и относительная погрешности

Абсолютная погрешность оценки параметра:

$$\Delta a = \hat{a} - a, \quad \Delta b = \hat{b} - b,$$

где a, b – истинные значения, $\hat{a}, \hat{b}$ – оценки. Относительная погрешность:

$$\delta a = \frac{|\Delta a|}{|a|} \cdot 100\%, \quad \delta b = \frac{|\Delta b|}{|b|} \cdot 100\%.$$

3 Реализация

Язык программирования: Python 3.13

Среда разработки: VS Code

Библиотеки:

- `numpy` – генерация данных и вычисления;
- `scipy.optimize` – минимизация для МНМ (метод Нелдера–Мида);
- `matplotlib.pyplot` – построение графиков.

Алгоритм программы:

1. Генерация x_i с шагом 0.2 на $[-1.8; 2]$.
2. Генерация ошибок $\varepsilon_i \sim N(0, 1)$ и вычисление y_i .
3. Расчёт оценок МНК аналитически (через `np.polyfit`).
4. Расчёт оценок МНМ численно (минимизация суммы модулей методом Нелдера–Мида).
5. Повторение с добавлением выбросов (изменение первого и последнего y).
6. Вычисление погрешностей и построение графиков с одинаковыми пределами по осям для обоих подграфиков.

4 Результаты

На рисунке 1 показаны диаграммы рассеяния и регрессионные прямые для двух случаев. Границы по осям установлены одинаковыми, чтобы обеспечить корректное визуальное сравнение. В таблице 1 приведены оценки параметров и их погрешности.




Рис. 1: Диаграммы рассеяния и линии регрессии (МНК – красный пунктир, МНМ – зелёный пунктир, истинная прямая – чёрная сплошная). Оси имеют одинаковый масштаб на обоих графиках.

Метод	a	Δa	$\delta a, \%$	b	Δb	$\delta b, \%$
МНК (без выбросов)	1.878	-0.122	6.08	1.502	-0.498	24.89
МНМ (без выбросов)	1.709	-0.291	14.54	1.563	-0.437	21.87
МНК (с выбросами)	2.021	0.021	1.07	0.074	-1.926	96.32
МНМ (с выбросами)	1.817	-0.183	9.13	1.407	-0.593	29.65

Таблица 1: Результаты оценивания параметров линейной регрессии

5 Обсуждение

Без выбросов

Даже в отсутствие аномальных наблюдений оба метода дали заметные погрешности, особенно для коэффициента b (наклона). Это связано с конкретной реализацией шума: при $n = 20$ и $\sigma = 1$ случайные отклонения могут быть значительными. МНК показал меньшую ошибку по a (6.08% против 14.54%), но большую по b (24.89% против 21.87%). В целом, ни один из методов не превзошёл другой явно в этом эксперименте.

С выбросами

После добавления двух сильных выбросов (скачок $+10$ в первой точке и -10 в последней) МНК претерпел катастрофическое смещение оценки наклона b : он упал до 0.074 при истинном значении 2, что дало относительную ошибку 96.32%. Это демонстрирует крайнюю чувствительность МНК к выбросам — одно аномальное наблюдение может полностью исказить оценку углового коэффициента. Оценка свободного члена a при этом, наоборот, улучшилась (погрешность снизилась с 6.08% до 1.07%). Это объясняется тем, что выбросы были добавлены симметрично (первая и последняя точки), что практически не изменило среднее значение y , а прямая МНК, став почти горизонтальной, проходит через центр облака, что случайно

приблизило a к истинному значению. Однако такое «улучшение» не является устойчивым и зависит от конкретного расположения выбросов.

МНМ оказался значительно устойчивее: его оценка b изменилась не так сильно (с 1.563 до 1.407, ошибка выросла с 21.87% до 29.65%), а оценка a изменилась умеренно (с 1.709 до 1.817, ошибка уменьшилась с 14.54% до 9.13%). Таким образом, МНМ сохраняет работоспособность при наличии выбросов, в отличие от МНК.

Визуализация

На графиках (рис. 1) с одинаковыми границами осей хорошо видно, как МНК «тянется» к выбросам: его прямая почти горизонтальна ($b \approx 0.07$). МНМ же продолжает следовать за основным облаком точек, хотя и с некоторым смещением.

6 Выводы

В ходе выполнения лабораторной работы были решены все поставленные задачи:

1. Сгенерированы данные с линейной зависимостью и нормальным шумом.
2. Реализованы два метода регрессии: МНК (аналитически) и МНМ (численно, методом Нелдера–Мида).
3. Исследовано влияние выбросов на оценки параметров.
4. Получены следующие результаты:
 - В отсутствие выбросов оба метода показали заметные погрешности из-за случайной реализации шума, причём МНК оказался немного лучше для a , но хуже для b .
 - При добавлении двух выбросов МНК сильно смещается (ошибка наклона достигла 96%), тогда как МНМ сохраняет приемлемую точность (ошибка наклона около 30%).
5. Построенные графики с одинаковыми границами осей наглядно демонстрируют робастность МНМ по сравнению с МНК.

Таким образом, метод наименьших модулей (L_1 -регрессия) является предпочтительным при анализе данных, содержащих выбросы, в то время как метод наименьших квадратов (L_2 -регрессия) может давать катастрофически неверные результаты даже при двух аномальных точках.

7 Список литературы

1. Кобзарь А.И. "Прикладная математическая статистика."— М.: Физматлит, 2006.
2. Документация библиотек NumPy, SciPy, Matplotlib: <https://docs.scipy.org/doc/>, <https://matplotlib.org/stable/contents.html>

8 Приложение

Ссылка на репозиторий с исходным кодом: <https://github.com/zhitkovns/matstat/tree/lab6>