

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Направление подготовки
"01.03.02. Прикладная математика и информатика"

Дисциплина "Математическая статистика"

Отчет по лабораторной работе №6

"Линейная регрессия. Метод наименьших квадратов и наименьших модулей"

Работу
выполнил:
Житков Н. С.
Группа:
5030102/30201

Санкт-Петербург
2026

Содержание

1	Постановка задачи	3
2	Теоретическая часть	3
3	Реализация	5
4	Результаты	5
5	Обсуждение	6
6	Выводы	6
7	Список литературы	7
8	Приложение	7

1 Постановка задачи

Цель работы: сравнить устойчивость двух методов оценивания параметров линейной регрессии — метода наименьших квадратов (МНК) и метода наименьших модулей (МНМ) — при наличии выбросов.

Задачи:

- Сгенерировать x_i равномерно на отрезке $[-1.8; 2]$ с шагом 0.2 (20 точек).
- Сгенерировать $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, где $\beta_0 = 2$, $\beta_1 = 2$, $\varepsilon_i \sim N(0, 1)$.
- Оценить параметры модели $y = \beta_0 + \beta_1 x$ двумя методами: МНК и МНМ (робастная версия по методичке).
- Повторить пункты 1–3, добавив выбросы: $y_1 \leftarrow y_1 + 10$, $y_{20} \leftarrow y_{20} - 10$.
- Построить графики регрессионных прямых и исходных данных с одинаковыми границами по осям для наглядности.
- Вычислить абсолютные и относительные погрешности оценок параметров.
- Сравнить результаты и сделать выводы об устойчивости методов.

2 Теоретическая часть

Модель простой линейной регрессии

Регрессионная модель описания данных называется **простой линейной регрессией**, если

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n,$$

где $x_1, \dots, x_n$ — заданные числа (значения фактора); $y_1, \dots, y_n$ — наблюдаемые значения отклика; $\varepsilon_1, \dots, \varepsilon_n$ — независимые, нормально распределённые $N(0, \sigma)$ случайные величины (ненаблюдаемые); β_0, β_1 — неизвестные параметры, подлежащие оцениванию.

Метод наименьших квадратов (МНК)

МНК минимизирует сумму квадратов остатков, т.е. квадрат L_2 -нормы:

$$Q(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \rightarrow \min_{\beta_0, \beta_1}.$$

Для нахождения минимума приравняем частные производные к нулю:

$$\frac{\partial Q}{\partial \beta_0} = -2 \sum (y_i - \beta_0 - \beta_1 x_i) = 0, \quad \frac{\partial Q}{\partial \beta_1} = -2 \sum x_i (y_i - \beta_0 - \beta_1 x_i) = 0.$$

Получаем систему нормальных уравнений:

$$\sum y_i = n\beta_0 + \beta_1 \sum x_i, \quad \sum x_i y_i = \beta_0 \sum x_i + \beta_1 \sum x_i^2.$$

Вводя выборочные средние $\bar{x} = \frac{1}{n} \sum x_i$, $\bar{y} = \frac{1}{n} \sum y_i$, $\overline{x^2} = \frac{1}{n} \sum x_i^2$, $\overline{xy} = \frac{1}{n} \sum x_i y_i$, получаем:

$$\hat{\beta}_1 = \frac{\overline{xy} - \bar{x}\bar{y}}{\overline{x^2} - (\bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

МНК-оценки оптимальны при нормальном распределении ошибок, но чувствительны к выбросам.

Метод наименьших модулей (МНМ)

МНМ минимизирует сумму абсолютных отклонений (L_1 -норму):

$$L(\beta_0, \beta_1) = \sum_{i=1}^n |y_i - \beta_0 - \beta_1 x_i| \rightarrow \min.$$

Аналитического решения не существует, однако можно построить робастные оценки, заменив в формулах МНК выборочные средние на медианы, а среднеквадратические отклонения – на интерквартильные широты, а также используя знаковый коэффициент корреляции (квадрантный). Робастные оценки $\hat{\beta}_{1R}$ и $\hat{\beta}_{0R}$ вычисляются по формулам:

$$\hat{\beta}_{1R} = r_Q \frac{q_y^*}{q_x^*}, \quad \hat{\beta}_{0R} = \text{med } y - \hat{\beta}_{1R} \text{med } x,$$

где q_x^* и q_y^* – нормированные интерквартильные широты, а r_Q – квадрантный (знаковый) коэффициент корреляции:

$$r_Q = \frac{1}{n} \sum_{i=1}^n \text{sgn}(x_i - \text{med } x) \text{sgn}(y_i - \text{med } y),$$

$$\text{sgn } z = \begin{cases} 1, & z > 0, \\ 0, & z = 0, \\ -1, & z < 0. \end{cases}$$

Интерквартильные широты (размахи) определяются через порядковые статистики:

$$q_x^* = \frac{x_{(j)} - x_{(l)}}{k_q(n)}, \quad q_y^* = \frac{y_{(j)} - y_{(l)}}{k_q(n)},$$

где $x_{(l)}$ – нижний квартиль, $x_{(j)}$ – верхний квартиль, а l и j – их номера в упорядоченной выборке. Номера квартилей находятся по правилу:

$$l = \begin{cases} [n/4] + 1, & n/4 \text{ дробное,} \\ n/4, & n/4 \text{ целое,} \end{cases} \quad j = n - l + 1.$$

Например, при $n = 20$: $n/4 = 5$ – целое, поэтому $l = 5$, $j = 20 - 5 + 1 = 16$. То есть нижним квартилем является 5-й по порядку элемент выборки, а верхним – 16-й. Разность $x_{(j)} - x_{(l)}$ даёт межквартильный размах (IQR). Параметр $k_q(n)$ – нормировочный коэффициент, зависящий от объёма выборки; он выбирается так, чтобы оценка была состоятельной. Для нормального распределения $k_q(n) \approx 1.34$. В работе принимается $k_q(n) = 1.34$ для всех n . Такая процедура обеспечивает устойчивость оценок к выбросам, поскольку медианы и квартили малочувствительны к аномальным наблюдениям, а знаковая функция учитывает только направление отклонения.

Абсолютная и относительная погрешности

Абсолютная погрешность оценки параметра:

$$\Delta\beta_0 = \hat{\beta}_0 - \beta_0, \quad \Delta\beta_1 = \hat{\beta}_1 - \beta_1.$$

Относительная погрешность:

$$\delta\beta_0 = \frac{|\Delta\beta_0|}{|\beta_0|} \cdot 100\%, \quad \delta\beta_1 = \frac{|\Delta\beta_1|}{|\beta_1|} \cdot 100\%.$$

3 Реализация

Язык программирования: Python 3.13

Среда разработки: VS Code

Библиотеки:

- `numpy` – генерация данных и вычисления;
- `matplotlib.pyplot` – построение графиков.

Алгоритм программы:

1. Генерация x_i с шагом 0.2 на $[-1.8; 2]$.
2. Генерация ошибок $\varepsilon_i \sim N(0, 1)$ и вычисление y_i .
3. Расчёт МНК-оценок по аналитическим формулам через средние.
4. Расчёт робастных МНМ-оценок по формулам (через медианы, квартили и знаковый коэффициент).
5. Повторение с добавлением выбросов (изменение первого и последнего y).
6. Вычисление погрешностей и построение графиков с одинаковыми пределами по осям для обоих подграфиков.

4 Результаты

На рисунке 1 показаны диаграммы рассеяния и регрессионные прямые для двух случаев. Границы по осям установлены одинаковыми, чтобы обеспечить корректное визуальное сравнение. В таблице 1 приведены оценки параметров и их погрешности.




Рис. 1: Диаграммы рассеяния и линии регрессии (МНК – красный пунктир, МНМ – зелёный пунктир, истинная прямая – чёрная сплошная). Оси имеют одинаковый масштаб на обоих графиках.

Метод	β_0	$\Delta\beta_0$	$\delta\beta_0, \%$	β_1	$\Delta\beta_1$	$\delta\beta_1, \%$
МНК (без выбросов)	1.878	-0.122	6.08	1.502	-0.498	24.89
МНМ (без выбросов)	2.022	0.022	1.12	0.988	-1.012	50.62
МНК (с выбросами)	2.021	0.021	1.07	0.074	-1.926	96.32
МНМ (с выбросами)	2.055	0.055	2.77	0.658	-1.342	67.08

Таблица 1: Результаты оценивания параметров линейной регрессии

5 Обсуждение

Без выбросов

В отсутствие аномальных наблюдений МНК дал погрешности 6.08% для β_0 и 24.89% для β_1 . Это объясняется случайным характером шума при малом объёме выборки ($n = 20$). Робастный МНМ показал для β_0 очень маленькую ошибку (1.12%), однако для наклона β_1 ошибка оказалась значительной – 50.62%. Это означает, что даже в отсутствие выбросов робастная версия МНМ может давать смещённые оценки, особенно для углового коэффициента, так как она основана на медианах и квартилях, которые «огрубляют» информацию.

С выбросами

После добавления двух сильных выбросов (скачок +10 в первой точке и –10 в последней) МНК претерпел катастрофическое смещение оценки наклона β_1 : он упал до 0.074 при истинном значении 2, что дало относительную ошибку 96.32%. Свободный член при этом оценился с ошибкой 1.07%. Это демонстрирует крайнюю чувствительность МНК к выбросам.

Робастный МНМ также изменил свои оценки, но не так драматично: β_1 упал до 0.658 (ошибка 67.08%), β_0 увеличился до 2.055 (ошибка 2.77%). Хотя наклон существенно искажён, это всё же гораздо ближе к истине, чем 0.074 у МНК. Таким образом, робастная версия МНМ действительно устойчивее к выбросам, хотя и не лишена смещения.

Визуализация

На графиках (рис. 1) с одинаковыми границами осей хорошо видно, как МНК «тянется» к выбросам: его прямая после внесения аномалий почти горизонтальна ($\beta_1 \approx 0.07$). Прямая МНМ также отклоняется, но её наклон остаётся заметно выше.

6 Выводы

В ходе выполнения лабораторной работы были решены все поставленные задачи:

1. Сгенерированы данные с линейной зависимостью и нормальным шумом.
2. Реализованы два метода регрессии: МНК (аналитически) и робастный МНМ (на основе медиан, интерквартильных широт и знакового коэффициента корреляции).
3. Исследовано влияние выбросов на оценки параметров.
4. Получены следующие результаты:

- В отсутствие выбросов МНК даёт заметные погрешности из-за малого объёма выборки; робастный МНМ хорошо оценивает свободный член, но сильно занижает наклон.
 - При добавлении двух выбросов МНК практически полностью «разрушается» (ошибка наклона более 96%), тогда как робастный МНМ сохраняет приемлемую оценку (ошибка наклона около 67%), что свидетельствует о его большей устойчивости.
5. Построенные графики с одинаковыми границами осей наглядно демонстрируют робастность МНМ по сравнению с МНК.

Таким образом, использование робастных оценок (медианы, квартили, знаковый коэффициент) целесообразно при анализе данных, содержащих выбросы. Однако следует помнить, что они могут давать смещение при нормальном распределении, поэтому выбор метода зависит от априорной информации о наличии аномальных наблюдений.

7 Список литературы

1. Кобзарь А.И. "Прикладная математическая статистика"— М.: Физматлит, 2006.
2. Документация библиотек NumPy и Matplotlib: <https://docs.scipy.org/doc/>, <https://matplotlib.org/stable/contents.html>
3. Бабахина С.А., Баженов А.Н. "Практикум по математической статистике: Учебное пособие."— СПб.: СПбПУ, 2026.

8 Приложение

Ссылка на репозиторий с исходным кодом: <https://github.com/zhitkovns/matstat/tree/lab6>